

chemflow

Skrining Virtual Otomatis dengan Python

Arif Maulana Azis

v2.0.0 · Lisensi MIT · github.com/Arifmaulanaazis/chemflow

Python 3.9+

RDKit

AutoDock Vina

OpenBabel

ADMETLab 3.0



Agenda: dari konsep in silico sampai menjalankan chemflow sendiri



A · Pembuka

Mengapa in silico dan apa itu chemflow



B · Python dan arsitektur

Ekosistem dan desain paket



C · Pipeline in silico

12 tahap, metode, rumus, analitik



D · Praktik

Instalasi, run, opsi, library



E · Diskusi dan penutup

Keterbatasan, referensi, tanya jawab


Tujuan belajar

- Menjelaskan alur virtual screening: preparasi, docking, ADMET, validasi
- Membaca keluaran chemflow secara kritis
- Menjalankan pipeline dari dua file Excel
- Mengenali keterbatasan sebelum menarik kesimpulan

Prasyarat

Python 3.9 atau lebih baru, OpenBabel, koneksi internet, dan Excel atau LibreOffice Calc. Tidak perlu pengalaman docking.

In silico memangkas daftar kandidat sebelum masuk laboratorium



Alur manual terpecah di banyak alat; chemflow menyatukannya

Alur manual

- 1 Cari SMILES di situs web
- 2 Siapkan ligan: konversi format, minimisasi
- 3 Siapkan protein: bersihkan, tambah H, muatan
- 4 Tentukan gridbox dengan tangan
- 5 Jalankan docking satu per satu
- 6 Salin skor ke spreadsheet
- 7 Buka situs ADMET, salin hasil
- 8 Buat grafik dan tabel sendiri

Dengan chemflow

```
python -m chemflow run \  
  --ligands ligan.xlsx \  
  --receptors reseptor.xlsx \  
  --run-rmsd-validation
```



Dapat diulang

Seed, konfigurasi, dan Excel tersimpan; run terhenti bisa dilanjutkan



Terdokumentasi

chemflow.log mencatat setiap tahap



Fail-soft

Satu ligan gagal, sisanya tetap diproses

chemflow sekilas: satu paket, satu perintah, siap publikasi

2.0.0

Versi

15,3 rb

Baris kode sumber, 73 modul

832

Tes unit lulus

120

Aturan klasifikasi ADMET

3.9+

Versi Python

MIT

Lisensi



Preparasi

Ligan dari SMILES atau nama senyawa; reseptor dari kode PDB



Docking

AutoDock Vina, multi-reseptor, multi-situs, replikasi, resume



Validasi

Native di-dock sebagai pembanding; RMSD in place



ADMET

ADMETLab3 otomatis atau dari file unduhan



Analitik

Bar, radar, heatmap, PCA gaya jurnal, HCA, per grup; 300 dpi



Similaritas

Pola interaksi terhadap native; BIOVIA otomatis di Windows

Run demonstrasi di deck ini: 10 ligan × 5 reseptor × 2 replikat = 100 docking dalam ±13 menit (Vina 1.2.7, exhaustiveness 16).

Ekosistem Python menutup seluruh rantai in silico



RDKit

Kemoinformatika: SMILES, konformasi 3D, MMFF94, deskriptor

≥ 2023.9.1



Open Babel

Konversi PDB ke PDBQT lewat subprocess. Bukan paket pip

biner eksternal



pandas · openpyxl

Baca Excel input, tulis workbook hasil berwarna

≥ 2.0 · ≥ 3.1



requests · bs4 · pubchempy

RCSB, PubChem, ADMETLab3, GitHub Releases

≥ 2.31 · ≥ 4.12 · ≥ 1.0.4



scikit-learn · scipy

PCA dan linkage Ward untuk kemometrik

≥ 1.3 · ≥ 1.10



matplotlib · numpy

Grafik 300 dpi dengan backend Agg

≥ 3.7 · ≥ 1.24



tqdm

Progress bar per tahap panjang

≥ 4.66



AutoDock Vina

Biner eksternal, diunduh otomatis. Demo memakai 1.2.7

bukan paket pip

Versi = batas bawah di pyproject.toml. Tanpa batas atas dan tanpa lock file, jadi hasil bisa bergeser antar versi pustaka.

Arsitektur berlapis: CLI tipis, orkestrator, modul domain



Konfigurasi terpusat

PipelineConfig menampung semua parameter dan memvalidasinya sejak awal.



Fail-soft

Kegagalan satu ligan atau reseptor dicatat; sisanya tetap diproses (pipeline.py:1-12).



Injeksi dependensi

Converter dan runner disuntik, sehingga tes tidak memerlukan OpenBabel, Vina, atau jaringan.



Tabel aturan tunggal

Satu tabel RULES ADMET menghasilkan warna sel, skor radar, dan sheet legenda.




CLI dan library

Satu basis kode: `python -m chemflow` atau `Pipeline(config).run()`.

Alur end-to-end: 12 tahap, sekuensial, fail-soft

Masukan: `ligan.xlsx` + `reseptor.xlsx`



Keluaran: `hasil_chemflow.xlsx` · `analytics/*.png` · `complexes/*.pdb` · `chemflow.log`

Semua tahap berjalan berurutan dalam satu proses. Setiap item yang selesai ditulis sebagai checkpoint di `_state/` dan folder hasil, sehingga chemflow resume `--output` hasil/ melanjutkan run yang terhenti tanpa mengulang tahap yang selesai.

Input: dua file Excel, satu untuk ligan dan satu untuk reseptor

ligan.xlsx

name	smiles	group
naproxen	(kosong)	Obat_Sintetis
paracetamol	(kosong)	Obat_Sintetis
omeprazole	(kosong)	Obat_Sintetis
aspirin	(kosong)	Obat_Sintetis
caffeine	(kosong)	Obat_Sintetis
luteolin	(kosong)	Senyawa_Alami
piperine	(kosong)	Senyawa_Alami
emodin	(kosong)	Senyawa_Alami
curcumin	(kosong)	Senyawa_Alami
berberine	(kosong)	Senyawa_Alami

Data demonstrasi: input run yang sama dengan hasil di slide berikutnya. Kolom native_ligand hanya catatan, tidak dibaca chemflow.

reseptor.xlsx

pdb_code	center_x	center_y	center_z	size_x/y/z	native_ligand
1UWH	75,153	44,833	65,026	22	BAX_A1723
4EY7	-14,108	-43,833	27,670	22	E20_A604
1HCK	100,541	97,891	81,717	19	ATP_A400
1HSG	13,073	22,467	5,557	23	MK1_B902
1EVE	2,781	64,383	67,971	20	E20_A2001

- **Tidy atau wide, otomatis.** Ada kolom smiles berarti tidy (satu baris satu senyawa). Tanpa kolom smiles berarti wide: tiap kolom satu kelompok, isi sel nama senyawa.
- **SMILES boleh kosong.** Nama senyawa dicari di PubChem. Kolom group dipakai PCA dan HCA (minimal 2 kelompok).
- **Gridbox opsional.** Bila kosong, chemflow menampilkan ligan native untuk dipilih. Kode PDB yang sama di beberapa baris berarti docking multi-situs.
- **Mulai cepat:** `python -m chemflow init` membuat templat dengan sheet Petunjuk.

Nama senyawa cukup: SMILES dicari otomatis di PubChem


Cuplikan chemflow.log (run demonstrasi)

```
23:22:31 === chemflow: memulai pipeline ===
23:22:31 [Ligan] Mode TIDY: nama='name', smiles='smiles',
group='group'
23:22:31 [Ligan] 10 senyawa dimuat (10 perlu resolusi PubChem, 2
kelompok terdeteksi).
23:22:31 Resolusi PubChem untuk 10 senyawa tanpa SMILES ...
23:22:42 [PubChem] 'curcumin' ->
COC1=C(C=CC(=C1)/C=C/C(=O)CC(=O)/C=C/C2=CC(=C(C=C2)O)OC)O
23:22:43 Ligan siap docking: 10/10
```


Nama file aman untuk Windows

- Karakter terlarang, spasi, kurung menjadi garis bawah
- Nama perangkat (CON, NUL, COM1) diberi garis bawah; aksara non-Latin menjadi unnamed_ + hash
- Nama kembar dirapikan dengan akhiran _2, _3; maksimal 60 karakter, menyusut agar path < 260


Struktur 2D dibuat RDKit dari SMILES hasil PubChem




curcumin



berberine



aspirin




caffeine

Bila PubChem gagal

Pemakai ditawarkan SMILES manual atau melewati senyawa itu. chemflow memakai hasil pertama untuk nama tersebut tanpa memeriksa kecocokan struktur.

Preparasi ligan: dari SMILES ke PDBQT siap docking



```


for factory in (AllChem.ETKDGv3, AllChem.ETKDGv2):
    params = factory()
    params.randomSeed = 42
    if AllChem.EmbedMolecule(mol, params) == 0:
        break
props = AllChem.MMFFGetMoleculeProperties(mol)
ff = AllChem.MMFFGetMoleculeForceField(mol, props)
ff.Minimize(maxIts=1000) # cadangan: UFFGetMoleculeForceField
  
```

ligand_preparer.py:155-195 (disederhanakan)

Muatan pada PDBQT ligan

Muatan Gasteiger dihitung OpenBabel saat konversi (--partialcharge gasteiger). Run demonstrasi memakai versi lama (muatan 0,000); pada uji ulang skor dan pose Vina identik.

Preparasi reseptor: satu struktur, dua keluaran terpisah



Logam dipertahankan: ZN, MG, FE, MN, CU, CO, NI, CA, NA, K, CD, HG. Residu HETATM dengan atom N, CA, C lengkap (mis. MSE) dianggap bagian protein.

prepare_for_docking menulis *_docking.pdbqt

- AddHs penuh, lalu buang H yang terikat karbon (sisakan H polar)
- Muatan parsial per residu dan nama atom (tabel, slide 13)
- Tipe atom AutoDock4: HD, A, NA, OA, SA
- Tulis PDBQT datar: reseptor rigid, TER per rantai

prepare_for_merge menulis *_clean.pdb

- Buang semua atom H
- Nolkan muatan formal dan properti muatan
- Tulis PDB polos. Bila Can't kekulize, ulangi tanpa penanda aromatik (receptor_preparer.py:126-153)

Mengapa dua jalur?

PDBQT ber-H polar dan muatan tidak boleh dipakai untuk file kompleks. Struktur yang dilihat pemakai di PyMOL atau Discovery Studio harus tampil polos.

Muatan parsial keluarga AMBER dan tipe atom AutoDock4

Muatan backbone (tabel di kollman_charges.py)

Atom	Muatan (e)
N	-0,4157
H amida	+0,2719
CA	+0,0337
HA	+0,0823
C karbonil	+0,5973
O karbonil	-0,5679

- **Rantai samping tercakup:** ASP, GLU, LYS, ARG, CYS/CYX, HID/HIE/HIP
- **Di luar tabel:** 0,0 (bawaan) atau Gasteiger via --kollman-fallback
- **Varian His/Cys** dipilih dari atom H yang ada (HD1/HE2, HG)


Tipe atom AutoDock4 (atom_typing.py)

Elemen	Kondisi	Tipe
H	tetangga bukan C	HD
H	tetangga C	H
C	aromatik	A
C	lainnya	C
N	aromatik, atau bukan amida	NA
N	berdekatan C=O (amida)	N
O	semua	OA
S	tanpa ikatan rangkap ke O	SA
S	sulfoksida atau sulfon	S

Catatan:

Vina tidak memakai Coulomb eksplisit, jadi cakupan tabel muatan berdampak kecil pada skor. Di run percobaan, 622 sampai 3.314 atom per reseptor jatuh ke muatan 0,0. Modul bernama Kollman, tetapi nilainya keluarga AMBER (Cornell et al. 1995).

Gridbox dihitung dari ligan native



pusat = rata-rata koordinat atom ligan


```
ukuran = min(ceil(max(L+8, 18)), 30) Å
```

L = sisi bounding-box terpanjang ligan

Gridbox nyata di run demonstrasi

Reseptor	Ligan native	Pusat (x, y, z) Å	Kotak Å
1UWH	BAX_A1723	75,153, 44,833, 65,026	22
4EY7	E20_A604	-14,108, -43,833, 27,670	22
1HCK	ATP_A400	100,541, 97,891, 81,717	19
1HSG	MK1_B902	13,073, 22,467, 5,557	23
1EVE	E20_A2001	2,781, 64,383, 67,971	20

chemflow receptor-config



- Ukuran yang diketik pemakai tidak dibatasi; batas 30 Å hanya untuk usulan otomatis (grid_box.py:9)
- Kode PDB yang sama di beberapa baris berarti multi-situs. Kuncinya 1UWH_R001, 1UWH_R002, dan seterusnya
- Tanpa gridbox di Excel, chemflow menampilkan daftar ligan native dan meminta pilihan (perlu terminal interaktif)
- Ukuran bawaan kotak diambil dari native itu; pusat tanpa ukuran di Excel memakai native terdekat (maks 8 Å). Opsi --default-box-size hanya cadangan tanpa native.

AutoDock Vina: diunduh otomatis, dijalankan dengan path lengkap

Resolusi biner

- 1 GET GitHub Releases API, tanpa autentikasi
- 2 Klasifikasi aset: sembilan regex per era nama, OS dan arsitektur
- 3 --vina-version memilih versi; bawaan: terbaru yang kompatibel
- 4 Unduh ke <output>/_cache/vina, chmod +x di POSIX
- 5 Jalankan lewat path absolut, tidak memakai PATH

```
vina --receptor R.pdbqt --ligand L.pdbqt \
  --out out.pdbqt --exhaustiveness 8 \
  --num_modes 9 --energy_range 3.0 \
  --center_x .. --center_y .. \
  --center_z .. --size_x .. \
  --size_y .. --size_z .. [--seed N]
```

8

exhaustiveness (bawaan; demo
memakai 16)

9

num_modes: pose per run

3,0

energy_range (kcal/mol)


acak

seed bawaan per replikat

Skor dan parsing

- Fungsi skor empiris: steric, hidrofobik, ikatan hidrogen, penalti torsi (Trott dan Olson 2010)
- Satuan kcal/mol; makin negatif makin baik; mode 1 = terbaik
- Tabel skor dibaca dari stdout: baris setelah -----+ yang berawalan angka
- --log tidak dipakai (tidak didukung Vina > 1.1.2). stdout distream, log ditulis manual

Matriks docking: ligan × reseptor × replikat, satu kegagalan tidak menghentikan yang lain



Kolom: 10 ligan sesuai urutan Excel (naproxen sampai berberine). Baris: 5 reseptor. Warna = skor terbaik dari kedua replikat; lebih gelap = lebih negatif.

```
seed = base_seed + replicate - 1
# atau random.randint(1, 2_000_000_000)
# bila --seed tidak diberikan
```

100

run docking

100/100

sukses

±8 mnt

waktu docking

2

replikat: seed 42, 43

- **Urutan loop:** reseptor, lalu ligan, lalu replikat (docking_matrix.py:122-127)
- **Kunci target:** <PDB>_R001; mendukung multi-situs dan multi-PDB
- **Statistik per pasangan:** rata-rata, simpangan baku populasi (ddof = 0), terbaik = minimum
- **Kegagalan:** dicatat di .error, matriks lanjut. Tiap run tersimpan di repNN.json dan dilewati saat resume. Eksekusi serial; Vina sendiri multithread


Validasi RMSD redocking: apakah protokol menemukan kembali ligan kristal?

- 1 Ekstrak blok PDB ligan native (koordinat kristal apa adanya)
- 2 SMILES templat dari RCSB Chemical Component Dictionary; AssignBondOrdersFromTemplate
- 3 Siapkan seperti ligan uji, lalu Vina di gridbox yang sama
- 4 Bandingkan pose terbaik dan kristal: hanya atom berat
- 5 CalcRMS in place (symmetry-aware); cadangan: greedy per unsur
- 6 Klasifikasi: < 2,0 Å baik; 2,0 sampai 3,0 Å cukup; ≥ 3,0 Å buruk

$$\text{RMSD} = \sqrt{\left(\frac{1}{N} \sum \| \mathbf{r}_i - \mathbf{r}_i' \|^2 \right)}$$

N atom berat; minimum atas pemetaan simetris. Ambang 2,0 Å mengacu pada Hevener dkk. (2009); pita 3,0 Å adalah pilihan chemflow.

RMSD redocking per reseptor (Å), data demonstrasi



Catatan metodologis

RMSD dihitung in place (rdMolAlign.CalcRMS, tanpa superposisi), jadi mengukur ketepatan posisi di kantong ikat sesuai konvensi redocking. Grafik dihitung ulang dari pose demonstrasi yang sama. Metode lama (best-fit) memberi 1HSG 4,04 Å; in place 10,52 Å, dan protokol perlu ditinjau.

ADMET: prediksi ADMETLab 3.0 langsung, atau dari file unduhan


Jalur A: scraper ADMETLab 3.0

- 1 GET /server/screening, ambil token CSRF
- 2 POST /server/screeningCal: SMILES unik, batch ≤ 50 (maks 100)
- 3 Cari tautan /download/csv/ di halaman hasil
- 4 Unduh CSV; baris ke-N = SMILES unik ke-N, disalin ke ligan kembar
- 5 Retry 5x, jeda 10 dtk x percobaan, untuk 429/5xx/timeout
- 6 Baris tak cocok: dicocokkan lewat raw_smiles, atau batch dilewati


Jalur B: --admet-file

CSV atau XLSX (sheet pertama) hasil unduhan ADMETLab3. Baris ke-N adalah ligan ke-N di Excel ligan, atau SMILES unik ke-N bila ada senyawa kembar antar grup (baris disalin); jumlah baris harus sama dengan salah satunya. Bila ada kolom smiles, dicocokkan dengan SMILES ligan dan memberi peringatan bila beda.

Aturan klasifikasi per kategori (total 120)



Satu tabel aturan mengubah 120 kolom ADMET menjadi lampu hijau, kuning, merah



Kolom	Hijau	Kuning atau merah
MW	100 sampai 600 Da	di luar rentang: merah
TPSA	0 sampai 140 Å ²	di luar rentang: merah
QED	> 0,67	selain itu merah
Lipinski	≤ 1 pelanggaran	selain itu merah
hERG, HIA, BBB	≤ 0,3	0,3 sampai 0,7 kuning; > 0,7 merah
cl-plasma	≤ 5 mL/min/kg	5 sampai 15 kuning; > 15 merah
PAINS, BMS	tanpa peringatan	ada peringatan: merah

`skor kategori = rata-rata(hijau 1,0 · kuning 0,5 · merah 0,0),
atas aturan terskor yang bukan N/A`

Sumber: admet_rules.py. 108 aturan terskor dan 12 deskriptif.

Fisikokimia: Lipinski Rule of Five dihitung lokal dengan RDKit

```
mw = Descriptors.MolWt(mol)
logp = Descriptors.MolLogP(mol) # Crippen
hbd = rdMolDescriptors.CalcNumLipinskiHBD(mol)
hba = rdMolDescriptors.CalcNumLipinskiHBA(mol)

violations = sum([mw > 500, logp > 5, hbd > 5, hba > 10])
passes_ro5 = violations <= 1
```

descriptors.py:62-67 dan :33


- **Batas Lipinski (1997):** $MW \leq 500$, $\log P \leq 5$, $HBD \leq 5$, $HBA \leq 10$; lolos bila pelanggaran ≤ 1
- **Dihitung pada mol ternetralkan** berhidrogen, tanpa perlu konformer 3D
- **Deskriptor tambahan** (TPSA, ikatan rotasi, cincin aromatik, Fsp3) ada di library tetapi belum dipakai pipeline
- **PCA, HCA, dan heatmap** memakai empat deskriptor ini: MW, LogP, HBD, HBA

Ligan	MW	LogP	HBD	HBA	Pelanggaran
naproxen	230,26	3,04	1	3	0
paracetamol	151,17	1,35	2	3	0
omeprazole	345,42	2,90	1	6	0
aspirin	180,16	1,31	1	4	0
caffeine	194,19	0,06	0	6	0
luteolin	286,24	2,13	4	6	0
piperine	285,34	3,00	0	4	0
emodin	270,24	1,89	3	5	0
curcumin	368,38	3,37	2	6	0
berberine	336,37	3,10	0	5	0

Data demonstrasi

Semua 10 ligan lolos Ro5 dengan 0 pelanggaran. Ro5 memprediksi potensi absorpsi oral, bukan aktivitas.

Merge: pose terbaik dan reseptor bersih menjadi satu file kompleks



Sidecar nyata dari run demonstrasi

Langkah merge_complex

- resName 3 karakter dari nama ligan; chain ligan = huruf bebas pertama, mundur dari X
- Atom ligan ditandai HETATM, residu 1, nama = unsur + indeks
- CombineMols dan satu konformer gabungan, disusun menurut posisi (bukan substruktur)
- TER disisipkan setelah blok reseptor dan blok ligan

Mode dan referensi

- **best**: satu file per pasangan; pose dari replikat terbaik secara global
- **all**: <ligan>_repNN_modeMM_complex.pdb untuk setiap pose. Demo: 181 file per reseptor (180 pose + 1 native)
- **NATIVE_<label>_complex.pdb**: ligan kristal asli (bukan hasil docking) sebagai baseline similaritas

Keluaran: folder terstruktur dan satu workbook Excel

```

hasil/
├─ chemflow.log
├─ hasil_chemflow.xlsx
├─ ligands/<nama>/          2D.png · .pdb · .pdbqt
├─ receptors/<PDB>_R001/    _docking.pdbqt · _clean.pdb
├─ docking/<PDB>_R001/<ligan>/ repNN_out.pdbqt · repNN.log
│   (ligan native: NATIVE_<label>/, isi sama)
├─ complexes/<PDB>_R001/    <ligan>_complex.pdb + .json
├─ analytics/              PNG (+ SVG, PDF)
├─ _state/                 config.json · progress.json ·
inputs/
├─ _cache/                 vina · ligand_templates


```

Kunci reseptor selalu <PDB>_R###, juga untuk satu situs (excel_receptors.py:46-49).

Sheet	Baris × kolom	Isi
Ringkasan Ligan	10 × 4	nama, nama_file, smiles, group, status
Hasil Docking	100 × 8	satu baris per run: seed, skor, jumlah pose
Fisikokimia (Lipinski)	10 × 7	MW, LogP, HBD, HBA, pelanggaran
ADMET	10 × 123	kolom ADMETLab3, sel berwarna
Legenda ADMET	120 × 7	kategori, satuan, ambang, rujukan
Validasi RMSD	5 × 7	RMSD, status, skor redock, metode
Statistik Replikasi	50 × 6	rata-rata, simpangan baku, terbaik

Baris data tanpa header, run demonstrasi. Sheet ditulis kondisional. Versi terbaru menambah kolom group, tipe, delta_vs_native, dan sheet per grup (lihat A5).

Analitik 1: heatmap dan peringkat afinitas dari matriks docking




Pasangan terbaik

curcumin dengan 4EY7: -11,05 kcal/mol (rerata dua replikat -10,92 ± 0,13).


Keluaran chemflow: heatmap_afinitas.png. Data demonstrasi: skor Vina terbaik dari 2 replikat (kcal/mol). Estimasi skor, bukan afinitas eksperimen.

Analitik 2: radar gabungan dan klasifikasi ADMET per kategori



radar_combined.png (data demonstrasi). ΔG docking = skor Vina.


Klasifikasi ADMET: Absorpsi



admet_klasifikasi_absorpsi.png (data demonstrasi, 10 ligan).

- Radar:** ΔG , MW, LogP, HBD, HBA dibalik (kecil = lebih baik) + skor tiap kategori ADMET; min-max per kriteria; enam ligan terbaik pada reseptor terbaik masing-masing
- Batang:** persentase ligan baik, sedang, buruk per parameter

Analitik 3: PCA dan HCA membaca ruang kimia senyawa



pca_2d.png (gaya jurnal, dihitung ulang dari data demonstrasi) dan hca_dendrogram.png.

Klaster k = 3: {caffeine, paracetamol, aspirin}, {naproxen, piperine, berberine}, {omeprazole, luteolin, emodin, curcumin}.

Cara baca

- Fitur: MW, LogP, HBD, HBA; z-score
- PCA: PC1 49,6%, PC2 28,9%, PC3 21,2%
- Elips 95% (χ^2 5,991) per kelompok, minimal 3 titik
- HCA: Ward, jarak Euclid
- Kedua kelompok sumber bercampur

Empat deskriptor tidak memisahkan kelompok sumber.

Similaritas interaksi: kemiripan pola kontak dengan ligan native

1 chemflow run

menghasilkan kompleks ligan dan NATIVE*_complex.pdb

2 Otomatis lewat BIOVIA (Windows)

Windows: tiap kompleks dibuka di GUI BIOVIA dengan input terkunci, diagram 2D dan tabel Non-bond diekspor sendiri; ekspor manual tetap bisa

3 Simpan berkas interaksi

interaksi/<PDB>_R001/<nama>_complex_interaksi.xlsx dan .png

4 chemflow similarity --output hasil/

membaca interaksi protein-ligan; ligan uji vs native

5 Keluaran

similaritas_interaksi.xlsx, similaritas_bar.png, similaritas_vs_deltag.png, similaritas_jejak_<reseptor>.png

$$\%sim = (0,5 \cdot nAAuji/nAAref + 0,5 \cdot intAAuji/intAAref) \times 100$$

nAA: residu yang berinteraksi dengan ligan uji dan ligan referensi. intAA: pasangan (residu, tipe interaksi) yang sama. ΔG = skor uji – skor referensi; negatif berarti lebih kuat dari native.



- Asimetris: mengukur cakupan kontak native, bukan Jaccard
- Kunci residu tanpa chain, jadi rantai kembar bisa menyatu
- ΔG referensi: terbaik-dari-n replikat native, seperti ligan uji

Diagram konsep tanpa data: run demonstrasi tidak memuat berkas interaksi BIOVIA. Metode: Pratama dkk. (2021).

Gaya publikasi bawaan: aman buta warna, 300 dpi, PNG, SVG, PDF

Palet kategorikal (analytics/style.py)



Semantik kualitas



Okabe dan Ito (2008). Palet ke-10 (#66C2A5) tambahan dari chemflow.



300 dpi, tiga format

--dpi dan --figure-formats png svg pdf; PNG selalu ditulis



Teks tetap teks

svg.fonttype none dan pdf.fonttype 42 agar bisa disunting di Illustrator atau Inkscape



Tidak mengubah global

Gaya lewat rc_context, jadi rcParams matplotlib pemanggil utuh



Label tanpa tumpang tindih

annotate_without_overlap mencoba beberapa posisi label



Teks grafik berbahasa Indonesia

Judul dan sumbu ditulis langsung di kode; naskah Inggris perlu render ulang

Instalasi dan cek kesiapan dalam lima menit

1 Pasang dependensi Python

```
pip install -r requirements.txt
pip install -e .
```

2 Pasang OpenBabel (contoh via conda)

```
conda create -n chemflow_tools \
  -c conda-forge openbabel -y
```

3 Cek kesiapan dan buat templat

```
python -m chemflow init --output contoh/
```

Yang perlu dicermati

Tanda !! berarti perlu perhatian. Di mesin ini OpenBabel belum ada di PATH, sehingga run memerlukan --openbabel-path. Vina tidak perlu dipasang: diunduh otomatis.

```
=== Pemeriksaan Kesiapan Mesin chemflow ===

[Python]
  OK  Versi interpreter: 3.14.6 (OK)
[Paket Python]
  OK  rdkit: terpasang (v2026.03.5)
  OK  pandas: terpasang (v3.0.5)
  OK  openpyxl: terpasang (v3.1.5)
  ... (9 paket diperiksa)
[Tool eksternal]
  !!  OpenBabel: tidak ditemukan di PATH
[AutoDock Vina]
  OK  GitHub Releases: 5 versi kompatibel
      tersedia: 1.2.7, 1.2.6, 1.2.5, 1.2.4, 1.2.3
[Jaringan]
  OK  RCSB (unduh struktur PDB): terjangkau
  OK  PubChem (resolusi SMILES): terjangkau
  OK  ADMETLab3 (prediksi ADMET): terjangkau
  OK  GitHub Releases (auto-download Vina): terjangkau

1 hal butuh perhatian (lihat tanda '!!' di atas).
```

Keluaran nyata python -m chemflow init (dipotong).

Menjalankan chemflow: dari gridbox sampai similaritas

```
# 1. susun reseptor.xlsx secara interaktif
python -m chemflow receptor-config
```

```
# 2. pipeline penuh (contoh perintah)
python -m chemflow run \
  --ligands ligan.xlsx \
  --receptors reseptor.xlsx \
  --output hasil/ \
  --run-rmsd-validation \
  --n-replicates 2 --exhaustiveness 16
```

```
# 3. lanjutkan run yang terhenti
python -m chemflow resume --output hasil/
```

```
# 4. opsional: interaksi BIOVIA, similaritas, dan GC-MS
python -m chemflow interactions --output hasil/
python -m chemflow similarity --output hasil/
python -m chemflow gcms --data data-gcms/ --output hasil/
```

Cuplikan chemflow.log run demonstrasi (path dipendekkan)

```
23:22:31 === chemflow: memulai pipeline ===
23:22:31 [Ligan] Mode TIDY: nama='name', smiles='smiles', group='group'
23:22:31 [Ligan] 10 senyawa dimuat (10 perlu resolusi PubChem, 2
kelompok terdeteksi).
23:22:31 Resolusi PubChem untuk 10 senyawa tanpa SMILES ...
23:22:42 [PubChem] 'curcumin' ->
COC1=C(C=CC(=C1)/C=C/C(=O)CC(=O)/C=C/C2=CC(=C(C=C2)O)OC)O
23:22:43 Ligan siap docking: 10/10
23:22:52 ADMET diperoleh untuk 10/10 senyawa.
23:22:52 Mengunduh Vina 1.2.7 (windows/x86_64) dari GitHub Releases
23:22:53 [Reseptor] Kolom gridbox ditemukan: center_x, center_y,
center_z
23:23:01 Reseptor siap docking: 5/5
23:23:01 [1/100] Docking 'naproxen' -> '1UWH_R001' (replikat 1/2)
23:23:04 Vina selesai: 9 pose, afinitas terbaik=-8.607 kcal/mol
23:31:14 [100/100] Docking 'berberine' -> '1EVE_R005' (replikat 2/2)
23:35:12 Hasil diekspor ke: hasil_chemflow.xlsx
23:35:28 PCA kemometrik berhasil dibuat.
23:35:29 === chemflow: pipeline selesai ===
```

Progress bar (tqdm) tampil di tiap tahap panjang; --no-progress mematikannya.

Cheat-sheet opsi dan pemecahan masalah umum

Opsi penting chemflow run

Opsi	Fungsi
<code>--run-rmsd-validation</code>	Hitung RMSD in place ligan native (native selalu di-dock)
<code>--n-replicates N</code>	Ulangi tiap docking N kali, seed berbeda
<code>--no-native</code>	Jangan dock ligan native (tanpa pembanding)
<code>--box-padding N</code>	Padding gridbox dari ukuran native (bawaan 8 Å)
<code>--exhaustiveness N</code>	Ketelitian pencarian Vina (bawaan 8)
<code>--seed N</code>	Seed dasar; replikat = seed + n - 1
<code>--merge-mode best all</code>	Satu pose terbaik atau semua pose
<code>--admet-file f</code>	Pakai file ADMETLab3 (.csv, .xlsx)
<code>--no-admet</code>	Lewati ADMET
<code>--openbabel-path p</code>	Lokasi obabel bila tak ada di PATH
<code>--no-interactive-gridbox</code>	Larang prompt; gridbox wajib di Excel
<code>--dpi, --figure-formats</code>	Resolusi dan format grafik
<code>--keep-waters</code>	Efektif hanya bersama <code>--keep-hetero-ligands</code> (perilaku kode saat ini)

Gejala dan solusi

Gejala	Penyebab dan solusi
Executable 'obabel' tidak ditemukan	Pasang OpenBabel atau pakai <code>--openbabel-path</code>
SMILES tidak ditemukan di PubChem	Isi kolom smiles, atau pakai nama internasional
ADMETLab3 429 atau timeout	Retry otomatis; lanjut <code>--admet-file</code> atau <code>--no-admet</code>
Jumlah baris file ADMET berbeda	Jumlah baris = ligan atau SMILES unik; urutan sama dengan Excel ligan
Proses berhenti menunggu	Pilih ligan native, atau isi gridbox / <code>--no-interactive-gridbox</code>
PCA atau HCA dilewati	Kolom group perlu minimal 2 nilai
Gagal mengunduh PDB	Kode salah, atau struktur hanya tersedia sebagai mmCIF
Path terlalu panjang (Windows)	Pilih folder output lebih pendek
Run terhenti di tengah	<code>chemflow resume --output hasil/</code> (lanjut dari checkpoint)
Grafik terpecah <code>_part01of03</code>	Wajar bila ligan atau reseptor banyak; atur <code>--plot-max-rows/cols</code> (0 = satu gambar)

Library Python: pipeline penuh atau komponen tunggal

Pipeline penuh

```
from chemflow import Pipeline, PipelineConfig

config = PipelineConfig(
    ligand_excel="ligan.xlsx",
    receptor_excel="reseptor.xlsx",
    output_dir="hasil",
    exhaustiveness=16,
    n_replicates=2,
    run_rmsd_validation=True,
)
exit_code = Pipeline(config).run() # 0 selesai, 1 fatal
# 130 bila Ctrl+C. Lanjutkan dengan:
Pipeline(config, resume=True).run()
```

Komponen tunggal

```
from rdkit import Chem
from chemflow import LipinskiCalculator, classify_admet_value

mol = Chem.MolFromSmiles("CC(=O)OC1=CC=CC=C1C(=O)O")
r = LipinskiCalculator.calculate(mol)
print(r.molecular_weight, r.violations, r.passes_ro5)

classify_admet_value("hERG", 0.82).flag # Flag.RED
```

64 nama publik diekspor dari chemflow/__init__.py, antara lain:

LigandPreparer

ReceptorPreparer

OpenBabelConverter

VinaReleaseManager

VinaRunner

GridBox

ChartBuilder

HeatmapBuilder

ChemometricPCA

HierarchicalClustering


SimilarityAnalyzer

run_gcms_analysis

Catatan: run() mengembalikan 0 walau tidak ada pasangan yang berhasil di-docking. Periksa log atau pipeline.failed_ligands dan failed_receptors.

Kualitas: 832 tes unit berjalan ± 76 detik tanpa jaringan

Jumlah tes per file, 12 terbanyak dari 58 file



832

tes lulus

58

file tes

75,7 dtk

waktu total

- **Sandbox:** OpenBabel, Vina, dan jaringan diganti kelas palsu atau monkeypatch (mis. `_FakeVinaRunner`)
- **Injeksi dependensi** membuat modul bisa dites terpisah: runner, converter, dan I/O interaktif disuntik
- **Lingkungan:** Python 3.14.6, pytest 9.1.1

Keterbatasan ilmiah sebelum menafsirkan hasil



RMSD in place bersifat ketat

RMSD in place mengukur ketepatan posisi, jadi ketat untuk ligan besar dan fleksibel: 1HSG 10,52 Å (4,04 Å bila diselaraskan dulu).



Skor Vina bukan afinitas eksperimen

Estimasi empiris (kcal/mol) dengan kecenderungan terhadap ukuran ligan. Validasi eksperimen tetap diperlukan.



Reseptor kaku dan model sederhana

Rigid, tanpa air, tanpa model protonasi (His menjadi HIE, gugus asam dan basa netral); muatan parsial hanya sebagian tercakup.



ADMET adalah prediksi model

Keluaran ADMETLab 3.0, bukan pengukuran. Pita 0,3/0,7 generik untuk sekitar 64 endpoint adalah asumsi.



Similaritas interaksi

Asimetris, kunci residu tanpa chain. Ekspor BIOVIA otomatis hanya di Windows; mouse dan keyboard dikunci selama ekspor.



Ruang kimia sempit

PCA dan HCA hanya memakai MW, LogP, HBD, HBA. Tanpa dinamika molekul atau perhitungan energi bebas.

Saran pelaporan

Catat versi Vina, exhaustiveness, seed, replikat, gridbox, dan padding; sebutkan RMSD dihitung in place; tulis bahwa skor adalah estimasi komputasi.

Keterbatasan teknis dan keamanan yang perlu dijaga saat dipakai



ADMETLab3 lewat scraping

Verifikasi TLS mati secara bawaan (`--admet-ssl-verify` untuk mengaktifkan). SMILES dikirim ke server pihak ketiga; ketentuan layanan belum ditinjau. Untuk jalur aman, pakai file unduhan.



Biner Vina tanpa checksum

Diunduh dari GitHub Releases dan dijalankan tanpa verifikasi checksum atau tanda tangan. Cache per folder output.



Serial, resume tersedia

Satu proses berurutan tanpa batas waktu subprocess; hasil per item tersimpan, jadi chemflow resume melanjutkan. `--cpu` tidak terekspos di CLI.



Kode keluar dan galat

`run()` bernilai 0 walau tidak ada yang berhasil di-docking. Galat konfigurasi muncul sebagai traceback.



Input terbatas

Hanya .pdb dari RCSB (bukan mmCIF) dan Excel .xlsx. Kolom PDBQT reseptor berlebih bila serial melewati 99.999.



Windows dan library

Batas path 260 karakter: nama file ligan dipendekkan otomatis. Mengimpor chemflow memaksa backend Agg matplotlib.

Referensi

1. Lipinski CA, Lombardo F, Dominy BW, Feeney PJ. Experimental and computational approaches to estimate solubility and permeability in drug discovery and development settings. *Adv Drug Deliv Rev.* 1997;23:3-25.
2. Trott O, Olson AJ. AutoDock Vina: improving the speed and accuracy of docking with a new scoring function, efficient optimization, and multithreading. *J Comput Chem.* 2010;31(2):455-461. doi:10.1002/jcc.21334
3. Eberhardt J, Santos-Martins D, Tillack AF, Forli S. AutoDock Vina 1.2.0: new docking methods, expanded force field, and Python bindings. *J Chem Inf Model.* 2021;61(8):3891-3898. doi:10.1021/acs.jcim.1c00203
4. Morris GM, Huey R, Lindstrom W, et al. AutoDock4 and AutoDockTools4: automated docking with selective receptor flexibility. *J Comput Chem.* 2009;30:2785-2791. doi:10.1002/jcc.21256
5. Fu L, Shi S, Yi J, et al. ADMETlab 3.0: an updated comprehensive online ADMET prediction platform enhanced with broader coverage, improved performance, API functionality and decision support. *Nucleic Acids Res.* 2024;52(W1):W422-W431. doi:10.1093/nar/gkae236
6. Xiong G, Wu Z, Yi J, et al. ADMETlab 2.0: an integrated online platform for accurate and comprehensive predictions of ADMET properties. *Nucleic Acids Res.* 2021;49(W1):W5-W14. doi:10.1093/nar/gkab255
7. Hevener KE, Zhao W, Ball DM, et al. Validation of molecular docking programs for virtual screening against dihydropteroate synthase. *J Chem Inf Model.* 2009;49(2):444-460. doi:10.1021/ci800293n
8. Pratama MRF, Poerwono H, Siswodihardjo S. Introducing a two-dimensional graph of docking score difference vs. similarity of ligand-receptor interactions. *Indones J Biotechnol.* 2021;26(1):54-60. doi:10.22146/ijbiotech.62194
9. Cornell WD, Cieplak P, Bayly CI, et al. A second generation force field for the simulation of proteins, nucleic acids, and organic molecules. *J Am Chem Soc.* 1995;117:5179-5197. doi:10.1021/ja00124a002
10. O'Boyle NM, Banck M, James CA, et al. Open Babel: an open chemical toolbox. *J Cheminform.* 2011;3:33. doi:10.1186/1758-2946-3-33
11. Okabe M, Ito K. Color Universal Design (CUD): how to make figures and presentations that are friendly to colorblind people. 2008.
12. Landrum G. RDKit: open-source cheminformatics. <https://www.rdkit.org>

Kesimpulan: dari dua Excel ke hasil yang dapat diuji ulang

1

Pipeline in silico dapat diotomasi dari dua file Excel dengan Python, RDKit, OpenBabel, dan AutoDock Vina.

2

Validasi redocking dan ADMET memberi konteks, tetapi skor docking tetap estimasi.

3

Keluaran siap publikasi: Excel berwarna, grafik 300 dpi, kompleks PDB.

4

Baca hasil secara kritis: tinjau RMSD, replikat, dan asumsi sebelum menyimpulkan.

Tanya jawab

Arif Maulana Azis · github.com/Arifmaulanaazis/chemflow · Lisensi MIT

Ambang ADMET (1/2): aturan dengan batas numerik

Fisikokimia (aturan numerik; alert dan tiered di A2)

Kolom	Parameter	Hijau bila
MW	Molecular Weight (Da)	100 s.d. 600
nHA	H-Bond Acceptors	0 s.d. 12
nHD	H-Bond Donors	0 s.d. 7
TPSA	TPSA (Å²)	0 s.d. 140
nRot	Rotatable Bonds	0 s.d. 11
nRing	Ring Count	0 s.d. 6
MaxRing	Max Ring Size (atoms)	0 s.d. 18
nHet	Heteroatom Count	1 s.d. 15
fChar	Formal Charge	-4 s.d. 4
nRig	Rigid Bonds	0 s.d. 30
nStereo	Stereo Centers	≤ 2
logS	logS (log mol/L)	-4 s.d. 0,5
logP	logP (log mol/L)	0 s.d. 3
logD	logD 7.4 (log mol/L)	1 s.d. 3
QED	QED	> 0,67
Synth	SAscore (1-10)	< 6
gasa	GASA (0/1)	0
Fsp3	Fsp3	≥ 0,42
MCE-18	MCE-18	≥ 45
Lipinski	Lipinski Rule (pelanggaran)	≤ 1
Pfizer	Pfizer Rule (pelanggaran)	≤ 1
GSK	GSK Rule (pelanggaran)	≤ 0
GoldenTriangle	Golden Triangle (pelanggaran)	≤ 0

Absorpsi, Distribusi, Ekskresi

Kolom	Parameter	Hijau bila
caco2	Caco-2 Permeability (log cm/s)	> -5,15
MDCK	MDCK Permeability (log cm/s)	≥ -5,7
PPB	Plasma Protein Binding (%)	≤ 90
VDss	VDss (log10(L/kg))	-1,4 s.d. 1,3
Fu	Fraction Unbound (%)	≥ 5
cl-plasma	Plasma Clearance (mL/min/kg)	≤ 5 hijau / 5-15 kuning / > 15 merah
t0.5	Half-life (jam)	> 8 hijau / 1-8 kuning / < 1 merah

Cara baca

Di luar batas hijau berarti merah, kecuali tipe tiered_range (Ekskresi) yang punya pita kuning. Batas strik (>, <) di kode ditulis dengan toleransi 1e-9. Sumber: admet_rules.py.

Ambang ADMET (2/2): kelompok probabilitas dan peringatan

Kategori	Tipe	Kolom
Fisikokimia	tiered: ≤ 0,3 hijau, ≤ 0,7 kuning, > 0,7 merah	Aggregators, Fluc, Blue_fluorescence, Green_fluorescence, Reactive, Promiscuous, Other_assay_interference
Fisikokimia	alert: tanpa peringatan hijau, ada peringatan merah	Alarm_NMR, BMS, Chelating, PAINS
Fisikokimia	deskriptif: tanpa ambang	Vol, Dense, Flex, mp, bp, pka_acidic, pka_basic, Natural Product-likeness
Absorpsi	tiered: ≤ 0,3 hijau, ≤ 0,7 kuning, > 0,7 merah	PAMPA, pgp_inh, pgp_sub, hia, f20, f30, f50
Distribusi	tiered: ≤ 0,3 hijau, ≤ 0,7 kuning, > 0,7 merah	OATP1B1, OATP1B3, BSEP, MRP1, BBB
Distribusi	tiered terbalik: ≤ 0,3 merah, ≤ 0,7 kuning, > 0,7 hijau	BCRP
Metabolisme	tiered: ≤ 0,3 hijau, ≤ 0,7 kuning, > 0,7 merah	CYP1A2-inh, CYP1A2-sub, CYP2C19-inh, CYP2C19-sub, CYP2C9-inh, CYP2C9-sub, CYP2D6-inh, CYP2D6-sub, CYP3A4-inh, CYP3A4-sub, CYP2B6-inh, CYP2B6-sub, CYP2C8-inh
Metabolisme	tiered terbalik: ≤ 0,3 merah, ≤ 0,7 kuning, > 0,7 hijau	LM-human
Toksistas	tiered: ≤ 0,3 hijau, ≤ 0,7 kuning, > 0,7 merah	Neurotoxicity-DI, Ototoxicity, Hematotoxicity, Nephrotoxicity-DI, Genotoxicity, RPMI-8226, A549, HEK293, hERG-10um, hERG, H-HT, DILI, Ames, ROA, FDAMDD, SkinSen, Carcinogenicity, EC, EI, Respiratory, NR-AhR, NR-AR, NR-AR-LBD, NR-Aromatase, NR-ER, NR-ER-LBD, NR-PPAR-gamma, SR-ARE, SR-ATAD5, SR-HSE, SR-MMP, SR-p53
Toksistas	alert: tanpa peringatan hijau, ada peringatan merah	LD50_oral, NonBiodegradable, NonGenotoxic_Carcinogenicity, SureChEMBL, Skin_Sensitization, Acute_Aquatic_Toxicity, Genotoxic_Carcinogenicity_Mutagenicity, FAF-Drugs4 Rule
Toksistas	deskriptif: tanpa ambang	BCF, IGC50, LC50DM, LC50FM

Semua opsi chemflow run (bawaan dalam kurung)

Grup	Opsi
Input	--ligands, --receptors (wajib); --output (chemflow_output)
Kolom Excel	--ligand-name-col, --ligand-smiles-col, --ligand-group-col, --receptor-pdb-col (otomatis)
Gridbox	--default-box-size (20.0, hanya cadangan); --box-padding (8.0); --no-interactive-gridbox
Preparasi ligan	--force-field {MMFF94, UFF} (MMFF94); --minimize-max-iters (1000); --no-2d-image
Preparasi reseptor	--keep-waters; --keep-hetero-ligands; --no-keep-metals; --kollman-fallback {zero, gasteiger} (zero)
Docking	--vina-version; --vina-executable; --exhaustiveness (8); --num-modes (9); --energy-range (3.0); --seed (acak); --n-replicates (1)
Merge	--merge-mode {best, all} (best)

Grup	Opsi
Native dan RMSD	--no-native; --run-rmsd-validation; --rmsd-threshold-good (2.0); --rmsd-threshold-acceptable (3.0)
Interaksi BIOVIA	--similarity / --no-similarity (otomatis bila terdeteksi); --biovia-exe (otomatis); --biovia-timeout (90); --no-lock-input
OpenBabel	--openbabel-path
ADMET	--no-admet; --admet-file; --admet-batch-size (50); --admet-ssl-verify
PubChem	--no-pubchem-fetch; --no-pubchem-interactive-fallback
Analitik	--no-charts; --no-pca; --no-hca; --no-heatmap; --dpi (300); --figure-formats {png, svg, pdf} (png); --plot-max-rows (30); --plot-max-cols (20)
GC-MS (opsional)	--gcms PATH...; --gcms-groups; --gcms-library
Logging	--verbose (tanpa efek saat ini); --log-level (INFO); --no-progress
Subperintah lain	init; resume --output DIR [--biovia-exe ...]; receptor-config; list-vina-versions; interactions --output DIR [--receptor --force --biovia-exe --biovia-timeout --no-lock-input]; similarity --output DIR [--interactions-dir --result-filename --no-plots -dpi]; gcms --output DIR [--data --groups --library --alkanes --scaling --normalization --permutations --no-plots]

Format PDBQT: reseptor datar, ligan dengan pohon torsi

Reseptor (4EY7_R002, 10.028 atom): 9 baris pertama

```
REMARK  Reseptor rigid, ditulis oleh chemflow.chem.pdbqt_writer
ATOM    1  N   GLU  A   4      2.514 -35.401  69.696  1.00  0.00   -0.416 NA
ATOM    2  CA  GLU  A   4      2.230 -35.193  68.280  1.00  0.00    0.034 C
ATOM    3  C   GLU  A   4      3.436 -35.566  67.408  1.00  0.00    0.597 C
ATOM    4  O   GLU  A   4      4.572 -35.606  67.889  1.00  0.00   -0.568 OA
ATOM    5  CB  GLU  A   4      1.808 -33.745  68.027  1.00  0.00    0.000 C
ATOM    6  CG  GLU  A   4      1.007 -33.544  66.749  1.00  0.00    0.000 C
ATOM    7  CD  GLU  A   4      0.729 -32.081  66.462  1.00  0.00    0.805 C
ATOM    8  OE1 GLU  A   4      1.240 -31.222  67.218  1.00  0.00   -0.819 OA
```

- **Kolom:** record PDB standar, lalu occupancy 1,00, B 0,00, muatan parsial (6 lebar), tipe AD4 (2 lebar)
- **Reseptor:** datar tanpa ROOT/BRANCH, TER per rantai. Ditulis chemflow, bukan OpenBabel, agar muatan tidak tertimpa
- **Ligan:** OpenBabel menulis REMARK torsi aktif, ROOT/ENDROOT, BRANCH/ENDBRANCH, dan TORSDOF
- **Tipe AD4 umum:** C, A, N, NA, OA, SA, HD, H
- **Run demonstrasi:** ligan versi lama bermuatan 0,000 (10 dari 10); versi sekarang menulis muatan Gasteiger. Reseptor tercakup tabel muatan sebagian

Ligan (curcumin): cuplikan

```
REMARK  12 active torsions:
ROOT
ATOM    1  C11 UNL    1      -0.715 -0.229 -2.653  1.00  0.00   +0.000 C
ENDROOT
BRANCH  1    2
ATOM    2  C10 UNL    1      0.550 -0.854 -2.134  1.00  0.00   +0.000 C
ATOM    3  O2  UNL    1      0.606 -2.063 -1.900  1.00  0.00   +0.000 OA
BRANCH  2    5
ATOM    4  C8  UNL    1      1.794  1.314 -1.914  1.00  0.00   +0.000 C
ATOM    5  C9  UNL    1      1.758 -0.026 -1.868  1.00  0.00   +0.000 C
...
ENDBRANCH 1    16
TORSDOF 10
```

Skema kolom setiap sheet hasil_chemflow.xlsx

Sheet	Kolom
Ringkasan Ligan	name, nama_file, smiles, group, tipe (uji atau native), status
Hasil Docking	ligand, group, receptor, replicate, seed, affinity_best, n_poses, status, error
Fisikokimia (Lipinski)	ligand, group, MW, LogP, HBD, HBA, Lipinski_Violations, Lolos_Ro5
ADMET	ligand, group, raw_smiles, smiles, lalu 120 kolom parameter ADMETLab3 berurutan per kategori (MW, Vol, Dense, ...)
Legenda ADMET	Kategori, Kolom, Label, Satuan, Ambang, Rujukan, Catatan
Validasi RMSD	receptor, native_ligand, rmsd_angstrom, status, redock_affinity, metode, catatan
Statistik Replikasi	ligand, group, receptor, n_replicates_success, affinity_mean, affinity_std, affinity_best, delta_vs_native
Ringkasan per Grup	grup, n_ligan, lolos_Ro5_persen, MW_rata2, LogP_rata2, HBD_rata2, HBA_rata2, ADMET_<kategori>
Docking per Grup	reseptor, grup, n_ligan, dG_rata2, dG_sd, dG_terbaik, dG_native

Nama kolom mengikuti versi terbaru; run demonstrasi lama belum memuat group, tipe, delta_vs_native, dan dua sheet per grup. Sheet ADMET diwarnai per sel menurut tabel aturan; header diwarnai per kategori.

Modul dan tanggung jawabnya

Modul	Tanggung jawab
pipeline.py	Orkestrasi 12 tahap, fail-soft, resume
cli.py	argparse: init, run, resume, receptor-config, interactions, similarity, gcms
config.py	PipelineConfig tervalidasi, to_dict/from_dict
state.py, checkpoints.py	Folder _state dan checkpoint atomik untuk resume
chem/ligand_preparer	SMILES ke PDB/PDBQT
chem/receptor_preparer	Bersihkan, H polar, dua keluaran
chem/kollman_charges	Muatan parsial (tabel AMBER)
chem/atom_typing	Tipe atom AutoDock4
chem/pdbqt_writer	PDBQT reseptor datar
chem/mol_converter	Pembungkus OpenBabel, muatan Gasteiger
chem/pubchem_client	SMILES dari nama
chem/descriptors	Lipinski dan deskriptor tambahan
io/excel_ligands, excel_receptors	Baca Excel (tidy, wide, gridbox)
io/pdb_fetcher	Unduh RCSB, ligan native
io/receptor_config	Excel reseptor interaktif
io/ligand_template	SMILES templat CCD RCSB
io/pdbqt_reader, result_exporter	Baca pose; tulis Excel berwarna
interaction/*	Ekspor interaksi lewat GUI BIOVIA (Windows), kunci input

Modul	Tanggung jawab
docking/vina_manager, vina_runner	Unduh biner Vina; jalankan dan parse skor
docking/docking_matrix	Loop ligan × reseptor × replikat, resume
docking/grid_box	Parameter gridbox, ukuran dari native
docking/rmsd_validation	RMSD in place (CalcRMS)
docking/merge	Kompleks PDB + JSON
admet/admetlab_scraper	Scraper ADMETLab 3.0
admet/admet_file	Baca CSV/XLSX ADMET
admet/dedup	SMILES unik, salin ke ligan kembar
admet/admet_rules	120 aturan klasifikasi
analytics/charts, heatmap	Bar, radar, heatmap (terpecah otomatis)
analytics/pca, hca	PCA gaya jurnal dan HCA
analytics/paging	Pemecahan plot menjadi bagian
analytics/group_stats, group_charts	Statistik dan grafik per grup
analytics/style	Gaya grafik bersama
similarity/*	Pembaca BIOVIA, rumus, plot, laporan
gcms/*	GC-MS: pembaca, sinyal, statistik, pustaka, grafik
utils/name_sanitizer, residue_backbone	Nama file aman, deteksi backbone
utils/subprocess_stream	Subprocess dan log (logging_setup)
templates, system_check, banner	Templat, cek kesiapan, header

Resume: melanjutkan run dari titik terakhir



Checkpoint atomik

Tiap item yang selesai (ligan, reseptor beserta gridbox, satu run Vina, hasil ADMET) ditulis ke file sementara lalu diganti atomik, jadi aman terhadap mati listrik.



Folder _state/

Berisi config.json, progress.json, salinan Excel input (inputs/), dan admet_cache.json. Path disimpan relatif, jadi folder hasil boleh dipindah.



chemflow resume

chemflow resume --output hasil/ membaca konfigurasi dari _state/ lalu melanjutkan. Ringkasan awal menyebut berapa ligan, reseptor, run docking, dan batch ADMET yang dipakai ulang.



Ctrl+C dan child process

Ctrl+C mengembalikan kode 130 dan mencetak perintah resume. Child process Vina ikut dimatikan, jadi tidak ada proses yatim setelah interupsi.



Dilewati dan diulang

Run Vina yang sukses dan berkas keluarannya ada dilewati. Run gagal, run terputus, atau checkpoint rusak diulang. Kompleks dianggap selesai bila PDB dan JSON-nya ada.



Setelan dan batasan

Log level serta jalur OpenBabel atau Vina boleh diganti saat resume; parameter ilmiah tetap dari run awal. Folder tanpa _state (versi lama) ditolak dengan pesan jelas.

Pemakaian

chemflow resume --output hasil/ · dari kode: Pipeline(RunState("hasil").load_config(), resume=True).run(). Ekspor Excel dan analitik selalu dibuat ulang karena murah.

Native, plot per grup, dan pemecahan plot otomatis



Native otomatis

Ligan native di-dock ulang dengan parameter dan replikat yang sama, lalu ikut ADMET, Lipinski, heatmap, PCA, dan HCA sebagai grup Native. Matikan dengan --no-native.



Gridbox dari native

Ukuran kubus = ekstensi native + padding 8 Å (minimal 18, maksimal 30). Berlaku pada mode interaktif dan Excel tanpa ukuran; --default-box-size hanya cadangan.



ADMET multi-grup

Senyawa yang sama di beberapa grup dikirim sekali (SMILES kanonik), lalu hasilnya disalin ke tiap ligan menurut indeksnya. Berlaku juga untuk --admet-file.



Plot per grup

Box plot ΔG per reseptor, heatmap grup $\times$ reseptor, persentase ligan lebih baik dari native, dan ADMET per grup (heatmap, radar, klasifikasi), plus sheet Ringkasan per Grup.



Pemecahan plot

Bila baris atau kolom melebihi --plot-max-rows (30) atau --plot-max-cols (20), gambar dibagi _part01of03 dan seterusnya dengan skala warna dan sumbu yang sama.



RMSD in place

RMSD native dihitung tanpa superposisi ulang (CalcRMS) dari pose terbaik lintas replikat. Ambang: $< 2,0$ Å baik, $2,0$ sampai $3,0$ Å cukup, $\geq 3,0$ Å buruk.

Cara membaca

Grup Native adalah pembanding: garis putus-putus pada plot ΔG dan kolom Native (ref) pada heatmap menunjukkan skor ligan kristal pada reseptor yang sama.

Interaksi otomatis dari BIOVIA untuk similaritas



Sekali jalan

chemflow run menyambung dari docking ke ekspor interaksi lalu similaritas, otomatis bila BIOVIA terdeteksi. chemflow interactions dan chemflow similarity tetap bisa dipakai terpisah.



Deteksi instalasi

DiscoveryStudio<tahun>.exe dicari di registry App Paths dan Program Files. Tahun terbaru dipilih, folder tanpa bin diabaikan, --biovia-exe menimpa.



Galat lisensi teratasi

Popen tidak membawa PATH dari registry App Paths yang dibutuhkan modul lisensi BIOVIA. chemflow menambahkannya, jadi BIOVIA terbuka tanpa galat lisensi.



Kendali lewat pohon UI

Tombol, tab, dan tabel dicari lewat nama dan kelas kontrol, bukan koordinat layar. Fokus jendela diperiksa sebelum tiap input dikirim; input Anda dikunci.



Keluaran

interaksi/<kunci>/<basis>_interaksi.png dan .xlsx (tabel Non-bond). Kompleks yang sudah lengkap dilewati, jadi ekspor yang terhenti bisa dilanjutkan.



Batasan

Hanya Windows. Mouse dan keyboard dikunci selama ekspor (sekitar 20 detik per kompleks); Esc tiga kali membatalkan. Diuji pada Discovery Studio 2021.

Perintah

```
python -m chemflow run --ligands ligan.xlsx --receptors reseptor.xlsx --output hasil/
```

Analisis GC-MS opsional (chemflow 2.0)



Mandiri dan opsional

chemflow gcms --data ... --output ... berjalan tanpa docking dan bisa diulang pada folder yang sama. chemflow run --gcms menambahkannya sebagai tahap akhir; tanpa argumen GC-MS pipeline tidak berubah.



Banyak format

Ekspor Shimadzu (xls, xlsx, txt), CSV/TSV, ANDI-MS .cdf, mzML, mzXML: kromatogram, tabel puncak, atau matriks fitur. Satuan RT, termasuk menit terkali 1000, dikoreksi otomatis.



Pemrosesan sinyal

Baseline ALS, Savitzky-Golay, penyalarsan RT lewat korelasi silang, deteksi puncak berbasis S/N, pengelompokan puncak antar sampel, dan sidik jari per bin waktu.



Kemometrik dan statistik

PCA gaya jurnal, HCA, kemiripan, uji univariat dengan koreksi FDR, PLS-DA dan LDA dengan validasi silang, uji permutasi, skor VIP, dan pencilan T2.



Identifikasi dan alergen

Nama dari laporan instrumen, pustaka RT atau RI, dan indeks Kovats. Skrining 24 alergen wewangian UE; senyawa bernama bersmiles jadi daftar ligan untuk docking.





Batasan

Hanya TIC, tanpa pencocokan spektrum. Persen luas puncak bukan konsentrasi. Model terawasi butuh minimal 6 sampel dan 2 per kelas, dan kurang bermakna dengan sedikit ulangan.

Perintah

```
python -m chemflow gcms --data data-gcms/ --output hasil/
```

GC-MS: PCA gaya jurnal dan kromatogram (data sintetis)



Cara baca

- Warna: seri (Mawar, Melati)
- Penanda: kelas (Asli, Tiruan)
- Elips 95% per kelas, gaya garis berbeda
- Puncak 12,0 dan 16,0 menit sengaja dibuat berbeda
- PLS-DA dan LDA: akurasi validasi silang 100%, p permutasi < 0,05

Data sintetis untuk ilustrasi, bukan hasil pengukuran.

pca_2d.png dan kromatogram_tumpang_tindih.png dari studi sintetis: 2 kelas x 2 seri x 3 ulangan.

Studi sintetis dibuat oleh tests/gcms_data.py; format masukan asli: xls, csv, cdf, mzML, mzXML.