# chemflow

## Skrining Virtual Otomatis dengan Python



**Arif Maulana Azis**

v2.1.0 · Lisensi MIT · github.com/Arifmaulanaazis/chemflow

Python 3.9+ | RDKit | AutoDock Vina | OpenBabel | ADMETLab 3.0

# Agenda: dari konsep in silico sampai menjalankan chemflow sendiri

### A · Pembuka
Mengapa in silico dan apa itu chemflow

### B · Python dan arsitektur
Ekosistem dan desain paket

### C · Pipeline in silico
12 tahap, metode, rumus, analitik

### D · Praktik
Instalasi, run, opsi, library

### E · Diskusi dan penutup
Keterbatasan, referensi, tanya jawab

## Tujuan belajar

- Menjelaskan alur virtual screening: preparasi, docking, ADMET, validasi
- Membaca keluaran chemflow secara kritis
- Menjalankan pipeline dari dua file Excel
- Mengenali keterbatasan sebelum menarik kesimpulan

## Prasyarat

Python 3.9 atau lebih baru, OpenBabel, koneksi internet, dan Excel atau LibreOffice Calc. Tidak perlu pengalaman docking.

A · PEMBUKA

# In silico memangkas daftar kandidat sebelum masuk laboratorium




Blok biru: tahap kerja chemflow (skrining virtual)

### Docking

Memprediksi pose dan skor ikatan ligan pada protein.

di chemflow

### ADMET

Memprediksi penyerapan, distribusi, metabolisme, ekskresi, toksisitas.

di chemflow

### Kemometrik dan QSAR

PCA, HCA, dan PLS-DA (GC-MS); QSAR menghubungkan struktur dan aktivitas.

tanpa QSAR

### Dinamika molekul

Menguji kestabilan kompleks dari waktu ke waktu.

di luar cakupan

# Alur manual terpecah di banyak alat; chemflow menyatukannya

## Alur manual

1. Cari SMILES di situs web
2. Siapkan ligan: konversi format, minimisasi
3. Siapkan protein: bersihkan, tambah H, muatan
4. Tentukan gridbox dengan tangan
5. Jalankan docking satu per satu
6. Salin skor ke spreadsheet
7. Buka situs ADMET, salin hasil
8. Buat grafik dan tabel sendiri

## Dengan chemflow

```
python -m chemflow run \
  --ligands ligan.xlsx \
  --receptors reseptor.xlsx \
  --run-rmsd-validation
```

**Dapat diulang**

Seed, konfigurasi, dan Excel tersimpan; run terhenti bisa dilanjutkan

**Terdokumentasi**

chemflow.log mencatat setiap tahap

**Fail-soft**

Satu ligan gagal, sisanya tetap diproses

A · PEMBUKA

# chemflow sekilas: satu paket, satu perintah, siap publikasi

| 2.1.0 | 15,3 rb | 846 | 120 | 3.9+ | MIT |
|---|---|---|---|---|---|
| Versi | Baris kode sumber, 73 modul | Tes unit lulus | Aturan klasifikasi ADMET | Versi Python | Lisensi |

### Preparasi

Ligan dari SMILES atau nama senyawa; reseptor dari kode PDB

### Docking

AutoDock Vina, multi-reseptor, multi-situs, replikasi, resume

### Validasi

Native di-dock sebagai pembanding; RMSD in place

### ADMET

ADMETLab3 otomatis atau dari file unduhan

### Analitik

Bar, radar, heatmap, PCA gaya jurnal, HCA, per grup; 300 dpi

### Similaritas

Pola interaksi terhadap native; BIOVIA otomatis di Windows

Run demonstrasi di deck ini: 10 ligan × 5 reseptor × 2 replikat = 100 docking dalam ±13 menit (Vina 1.2.7, exhaustiveness 16).

# Ekosistem Python menutup seluruh rantai in silico

### RDKit

Kemoinformatika: SMILES, konformasi 3D, MMFF94, deskriptor

≥ 2023.9.1

### Open Babel

Konversi PDB ke PDBQT lewat subprocess. Bukan paket pip

biner eksternal

### pandas · openpyxl

Baca Excel input, tulis workbook hasil berwarna

≥ 2.0 · ≥ 3.1

### requests · bs4 · pubchempy

RCSB, PubChem, ADMETLab3, GitHub Releases

≥ 2.31 · ≥ 4.12 · ≥ 1.0.4

### scikit-learn · scipy

PCA dan linkage Ward untuk kemometrik

≥ 1.3 · ≥ 1.10

### matplotlib · numpy

Grafik 300 dpi dengan backend Agg

≥ 3.7 · ≥ 1.24

### tqdm

Progress bar per tahap panjang

≥ 4.66

### AutoDock Vina

Biner eksternal, diunduh otomatis. Demo memakai 1.2.7

bukan paket pip

Versi = batas bawah di pyproject.toml. Tanpa batas atas dan tanpa lock file, jadi hasil bisa bergeser antar versi pustaka.

# Arsitektur berlapis: CLI tipis, orkestrator, modul domain




### Konfigurasi terpusat

PipelineConfig menampung semua parameter dan memvalidasinya sejak awal.

### Fail-soft

Kegagalan satu ligan atau reseptor dicatat; sisanya tetap diproses (pipeline.py:1-12).

### Injeksi dependensi

Converter dan runner disuntik, sehingga tes tidak memerlukan OpenBabel, Vina, atau jaringan.

### Tabel aturan tunggal

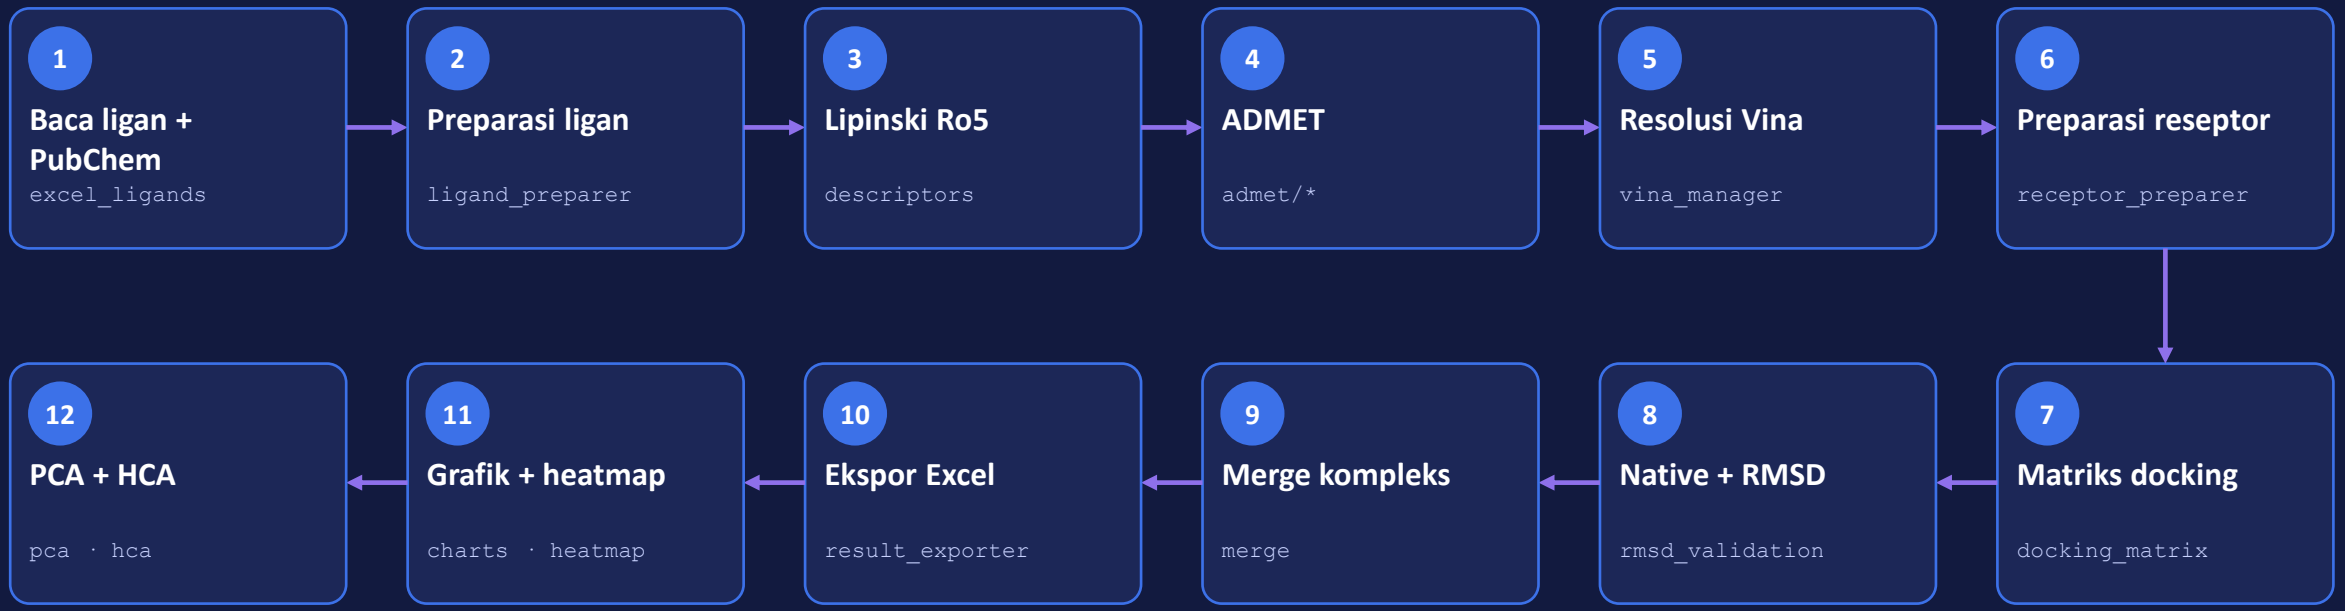
Satu tabel RULES ADMET menghasilkan warna sel, skor radar, dan sheet legenda.

### CLI dan library

Satu basis kode: python -m chemflow atau Pipeline(config).run().

# Alur end-to-end: 12 tahap, sekuensial, fail-soft

**Masukan: ligan.xlsx + reseptor.xlsx**




**Keluaran: hasil_chemflow.xlsx · analytics/*.png · complexes/*.pdb · chemflow.log**

Semua tahap berjalan berurutan dalam satu proses. Setiap item yang selesai ditulis sebagai checkpoint di _state/ dan folder hasil, sehingga chemflow resume --output hasil/ melanjutkan run yang terhenti tanpa mengulang tahap yang selesai.

# Input: dua file Excel, satu untuk ligan dan satu untuk reseptor

## ligan.xlsx

| name | smiles | group |
|---|---|---|
| naproxen | *(kosong)* | Obat_Sintetis |
| paracetamol | *(kosong)* | Obat_Sintetis |
| omeprazole | *(kosong)* | Obat_Sintetis |
| aspirin | *(kosong)* | Obat_Sintetis |
| caffeine | *(kosong)* | Obat_Sintetis |
| luteolin | *(kosong)* | Senyawa_Alami |
| piperine | *(kosong)* | Senyawa_Alami |
| emodin | *(kosong)* | Senyawa_Alami |
| curcumin | *(kosong)* | Senyawa_Alami |
| berberine | *(kosong)* | Senyawa_Alami |

Data demonstrasi: input run yang sama dengan hasil di slide berikutnya. Kolom native_ligand hanya catatan, tidak dibaca chemflow.

## reseptor.xlsx

| pdb_code | center_x | center_y | center_z | size_x/y/z | native_ligand |
|---|---|---|---|---|---|
| 1UWH | 75,153 | 44,833 | 65,026 | 22 | BAX_A1723 |
| 4EY7 | −14,108 | −43,833 | 27,670 | 22 | E20_A604 |
| 1HCK | 100,541 | 97,891 | 81,717 | 19 | ATP_A400 |
| 1HSG | 13,073 | 22,467 | 5,557 | 23 | MK1_B902 |
| 1EVE | 2,781 | 64,383 | 67,971 | 20 | E20_A2001 |

- **Tidy atau wide, otomatis.** Ada kolom smiles berarti tidy (satu baris satu senyawa). Tanpa kolom smiles berarti wide: tiap kolom satu kelompok, isi sel nama senyawa.
- **SMILES boleh kosong.** Nama senyawa dicari di PubChem. Kolom group dipakai PCA dan HCA (minimal 2 kelompok).
- **Gridbox opsional.** Bila kosong, chemflow menampilkan ligan native untuk dipilih. Kode PDB yang sama di beberapa baris berarti docking multi-situs.
- **Mulai cepat:** python -m chemflow init membuat templat dengan sheet Petunjuk.

# Nama senyawa cukup: SMILES dicari otomatis di PubChem

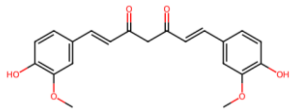
### Cuplikan chemflow.log (run demonstrasi)

```
23:22:31 === chemflow: memulai pipeline ===
23:22:31 [Ligan] Mode TIDY: nama='name', smiles='smiles',
group='group'
23:22:31 [Ligan] 10 senyawa dimuat (10 perlu resolusi PubChem, 2
kelompok terdeteksi).
23:22:31 Resolusi PubChem untuk 10 senyawa tanpa SMILES ...
23:22:42 [PubChem] 'curcumin' ->
COC1=C(C=CC(=C1)/C=C/C(=O)CC(=O)/C=C/C2=CC(=C(C=C2)O)OC)O
23:22:43 Ligan siap docking: 10/10
```

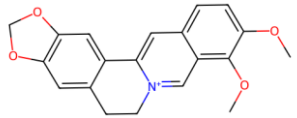
### Nama file aman untuk Windows

- Karakter terlarang, spasi, kurung menjadi garis bawah
- Nama perangkat (CON, NUL, COM1) diberi garis bawah; aksara non-Latin menjadi unnamed_ + hash
- Nama kembar dirapikan dengan akhiran _2, _3; maksimal 60 karakter, menyusut agar path < 260

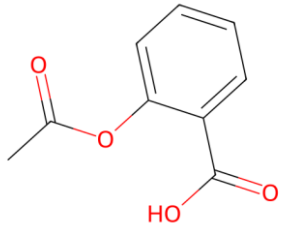
### Struktur 2D dibuat RDKit dari SMILES hasil PubChem



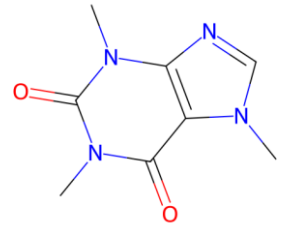
**curcumin**



**berberine**




**aspirin**

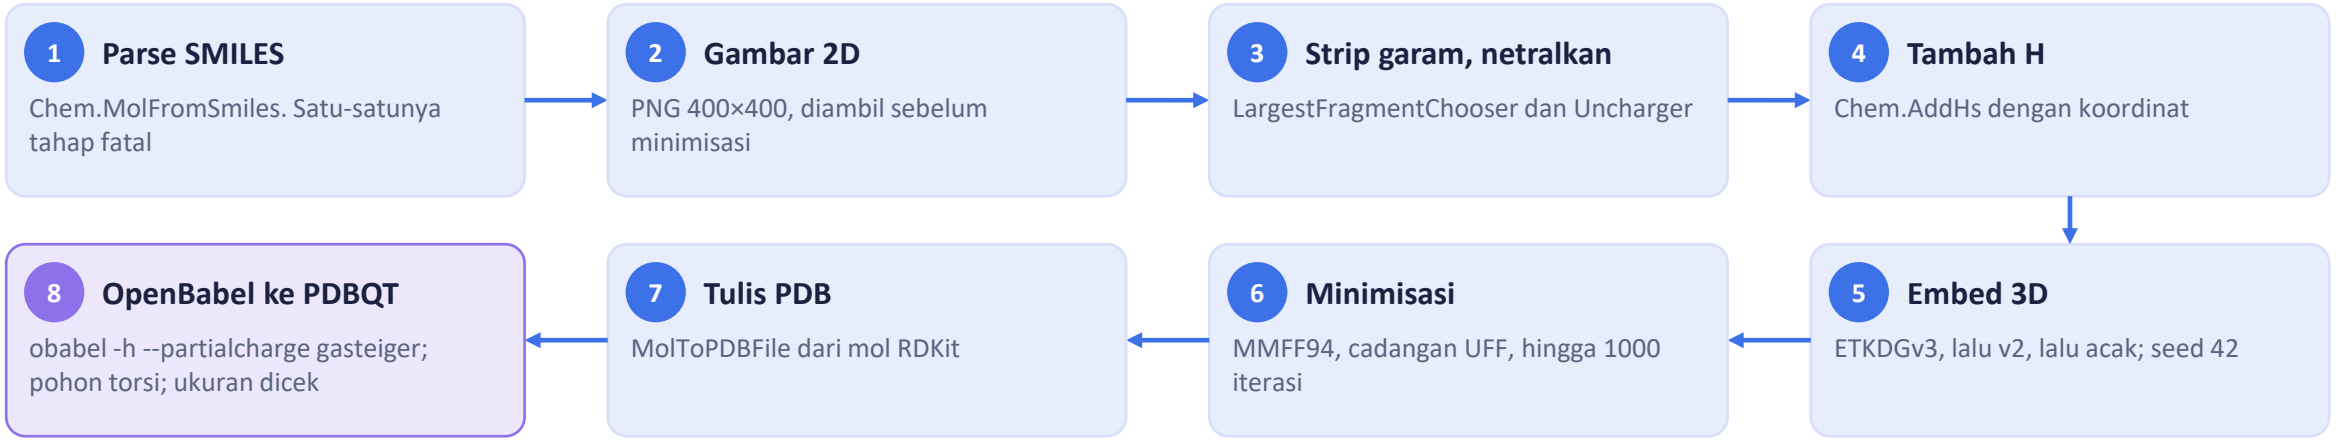



**caffeine**

**Bila PubChem gagal**

Pemakai ditawari SMILES manual atau melewati senyawa itu. chemflow memakai hasil pertama untuk nama tersebut tanpa memeriksa kecocokan struktur.

# Preparasi ligan: dari SMILES ke PDBQT siap docking




```
for factory in (AllChem.ETKDGv3, AllChem.ETKDGv2):
    params = factory()
    params.randomSeed = 42
    if AllChem.EmbedMolecule(mol, params) == 0:
        break
props = AllChem.MMFFGetMoleculeProperties(mol)
ff = AllChem.MMFFGetMoleculeForceField(mol, props)
ff.Minimize(maxIts=1000)    # cadangan: UFFGetMoleculeForceField
```

ligand_preparer.py:155-195 (disederhanakan)

## Muatan pada PDBQT ligan

Muatan Gasteiger dihitung OpenBabel saat konversi (--partialcharge gasteiger). Run demonstrasi memakai versi lama (muatan 0,000); pada uji ulang skor dan pose Vina identik.

# Preparasi reseptor: satu struktur, dua keluaran terpisah

**1 RCSB .pdb**
Diunduh dan di-cache. Format PDB saja, bukan mmCIF

→

**2 Muat RDKit**
proximityBonding, sanitasi tidak fatal

→

**3 Bersihkan**
Air dibuang; HETATM dibuang kecuali logam dan residu backbone lengkap

Logam dipertahankan: ZN, MG, FE, MN, CU, CO, NI, CA, NA, K, CD, HG. Residu HETATM dengan atom N, CA, C lengkap (mis. MSE) dianggap bagian protein.

**prepare_for_docking menulis *_docking.pdbqt**

- AddHs penuh, lalu buang H yang terikat karbon (sisakan H polar)
- Muatan parsial per residu dan nama atom (tabel, slide 13)
- Tipe atom AutoDock4: HD, A, NA, OA, SA
- Tulis PDBQT datar: reseptor rigid, TER per rantai

**prepare_for_merge menulis *_clean.pdb**

- Buang semua atom H
- Nolkan muatan formal dan properti muatan
- Tulis PDB polos. Bila Can't kekulize, ulangi tanpa penanda aromatik (receptor_preparer.py:126-153)

**Mengapa dua jalur?**
PDBQT ber-H polar dan muatan tidak boleh dipakai untuk file kompleks. Struktur yang dilihat pemakai di PyMOL atau Discovery Studio harus tampil polos.

# Muatan parsial keluarga AMBER dan tipe atom AutoDock4

### Muatan backbone (tabel di kollman_charges.py)

| Atom | Muatan (e) |
|---|---|
| N | −0,4157 |
| H amida | +0,2719 |
| CA | +0,0337 |
| HA | +0,0823 |
| C karbonil | +0,5973 |
| O karbonil | −0,5679 |

- **Rantai samping tercakup:** ASP, GLU, LYS, ARG, CYS/CYX, HID/HIE/HIP
- **Di luar tabel:** 0,0 (bawaan) atau Gasteiger via --kollman-fallback
- **Varian His/Cys** dipilih dari atom H yang ada (HD1/HE2, HG)

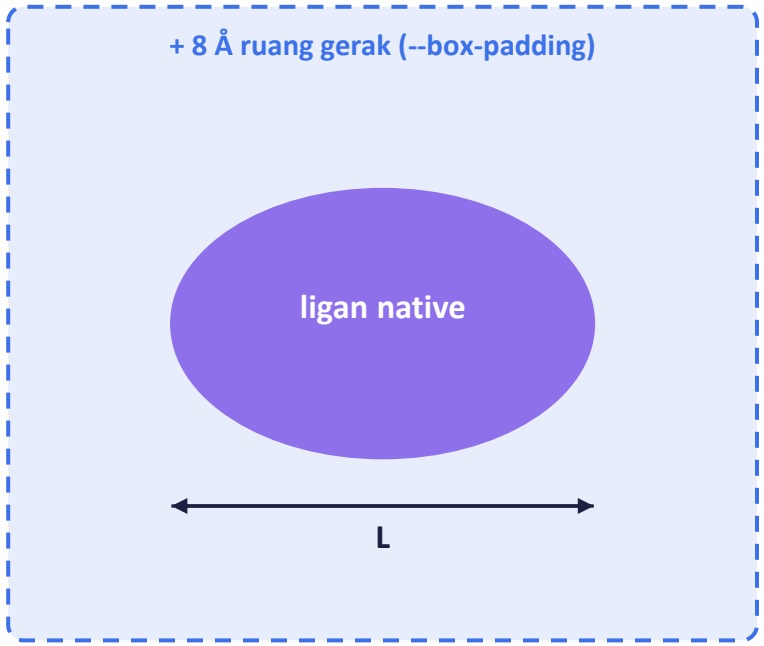
### Tipe atom AutoDock4 (atom_typing.py)

| Elemen | Kondisi | Tipe |
|---|---|---|
| H | tetangga bukan C | HD |
| H | tetangga C | H |
| C | aromatik | A |
| C | lainnya | C |
| N | aromatik, atau bukan amida | NA |
| N | berdekatan C=O (amida) | N |
| O | semua | OA |
| S | tanpa ikatan rangkap ke O | SA |
| S | sulfoksida atau sulfon | S |

**Catatan:**

Vina tidak memakai Coulomb eksplisit, jadi cakupan tabel muatan berdampak kecil pada skor. Di run percobaan, 622 sampai 3.314 atom per reseptor jatuh ke muatan 0,0. Modul bernama Kollman, tetapi nilainya keluarga AMBER (Cornell et al. 1995).

# Gridbox dihitung dari ligan native




pusat = rata-rata koordinat atom ligan

```
ukuran = min(ceil(max(L+8, 18)), 30) Å
```

L = sisi bounding-box terpanjang ligan

### Gridbox nyata di run demonstrasi

| Reseptor | Ligan native | Pusat (x, y, z) Å | Kotak Å |
|---|---|---|---|
| 1UWH | BAX_A1723 | 75,153, 44,833, 65,026 | 22 |
| 4EY7 | E20_A604 | −14,108, −43,833, 27,670 | 22 |
| 1HCK | ATP_A400 | 100,541, 97,891, 81,717 | 19 |
| 1HSG | MK1_B902 | 13,073, 22,467, 5,557 | 23 |
| 1EVE | E20_A2001 | 2,781, 64,383, 67,971 | 20 |

`chemflow receptor-config`

**1 Kode PDB** → **2 Pilih ligan native** → **3 Ukuran kotak** → **4 reseptor.xlsx**

- Ukuran yang diketik pemakai tidak dibatasi; batas 30 Å hanya untuk usulan otomatis (grid_box.py:9)
- Kode PDB yang sama di beberapa baris berarti multi-situs. Kuncinya 1UWH_R001, 1UWH_R002, dan seterusnya
- Tanpa gridbox di Excel, chemflow menampilkan daftar ligan native dan meminta pilihan (perlu terminal interaktif)
- Ukuran bawaan kotak diambil dari native itu; pusat tanpa ukuran di Excel memakai native terdekat (maks 8 Å). Opsi --default-box-size hanya cadangan tanpa native.

# AutoDock Vina: diunduh otomatis, dijalankan dengan path lengkap

## Resolusi biner

1. GET GitHub Releases API, tanpa autentikasi
2. Klasifikasi aset: sembilan regex per era nama, OS dan arsitektur
3. --vina-version memilih versi; bawaan: terbaru yang kompatibel
4. Unduh ke <output>/_cache/vina, chmod +x di POSIX
5. Jalankan lewat path absolut, tidak memakai PATH

```
vina --receptor R.pdbqt --ligand L.pdbqt \
     --out out.pdbqt --exhaustiveness 8 \
     --num_modes 9 --energy_range 3.0 \
     --center_x .. --center_y .. \
     --center_z .. --size_x .. \
     --size_y .. --size_z .. [--seed N]
```

**8**
exhaustiveness (bawaan; demo memakai 16)

**9**
num_modes: pose per run

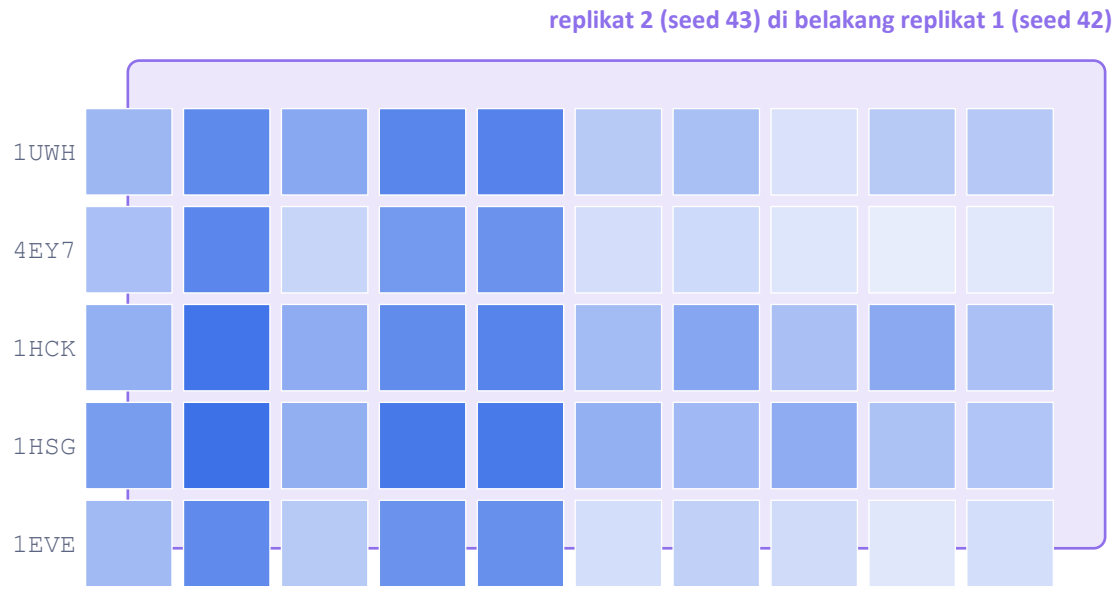
**3,0**
energy_range (kcal/mol)

**acak**
seed bawaan per replikat

## Skor dan parsing

- Fungsi skor empiris: steric, hidrofobik, ikatan hidrogen, penalti torsi (Trott dan Olson 2010)
- Satuan kcal/mol; makin negatif makin baik; mode 1 = terbaik
- Tabel skor dibaca dari stdout: baris setelah -----+ yang berawalan angka
- --log tidak dipakai (tidak didukung Vina > 1.1.2). stdout distream, log ditulis manual

# Matriks docking: ligan × reseptor × replikat, satu kegagalan tidak menghentikan yang lain




Kolom: 10 ligan sesuai urutan Excel (naproxen sampai berberine). Baris: 5 reseptor. Warna = skor terbaik dari kedua replikat; lebih gelap = lebih negatif.

```
seed = base_seed + replicate - 1
# atau random.randint(1, 2_000_000_000)
#   bila --seed tidak diberikan
```

**100**
run docking

**100/100**
sukses

**±8 mnt**
waktu docking

**2**
replikat: seed 42, 43

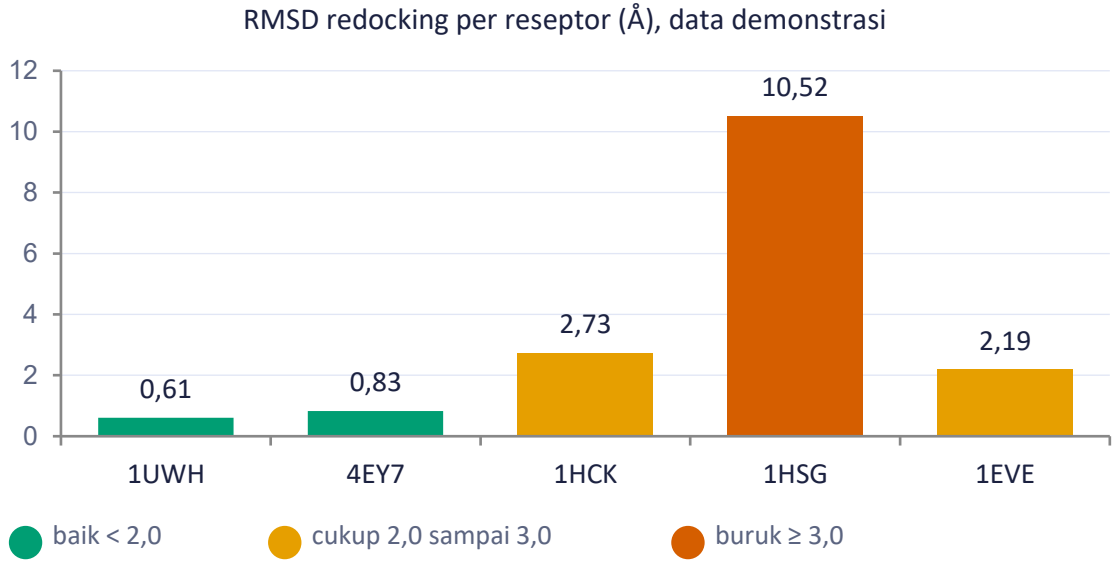
- **Urutan loop:** reseptor, lalu ligan, lalu replikat (docking_matrix.py:122-127)
- **Kunci target:** <PDB>_R001; mendukung multi-situs dan multi-PDB
- **Statistik per pasangan:** rata-rata, simpangan baku populasi (ddof = 0), terbaik = minimum
- **Kegagalan:** dicatat di .error, matriks lanjut. Tiap run tersimpan di repNN.json dan dilewati saat resume. Eksekusi serial; Vina sendiri multithread

# Validasi RMSD redocking: apakah protokol menemukan kembali ligan kristal?

1. Ekstrak blok PDB ligan native (koordinat kristal apa adanya)
2. SMILES templat dari RCSB Chemical Component Dictionary; AssignBondOrdersFromTemplate
3. Siapkan seperti ligan uji, lalu Vina di gridbox yang sama
4. Hitung RMSD semua pose dan replikat; pilih minimum
5. CalcRMS in place (symmetry-aware); cadangan: greedy per unsur
6. Klasifikasi: < 2,0 Å baik; 2,0 sampai 3,0 Å cukup; ≥ 3,0 Å buruk

$$\mathrm{RMSD} = \sqrt{\left( (1/N) \sum \|r_i - r_i'\|^2 \right)}$$

N atom berat; minimum atas pemetaan simetris. Ambang 2,0 Å mengacu pada Hevener dkk. (2009); pita 3,0 Å adalah pilihan chemflow.




**Catatan metodologis**

RMSD dihitung in place (rdMolAlign.CalcRMS, tanpa superposisi), jadi mengukur ketepatan posisi di kantong ikat sesuai konvensi redocking. Grafik adalah data demonstrasi versi sebelumnya, bukan hasil seleksi semua pose pada v2.1.0. Kini best memilih RMSD minimum, bukan afinitas terendah.

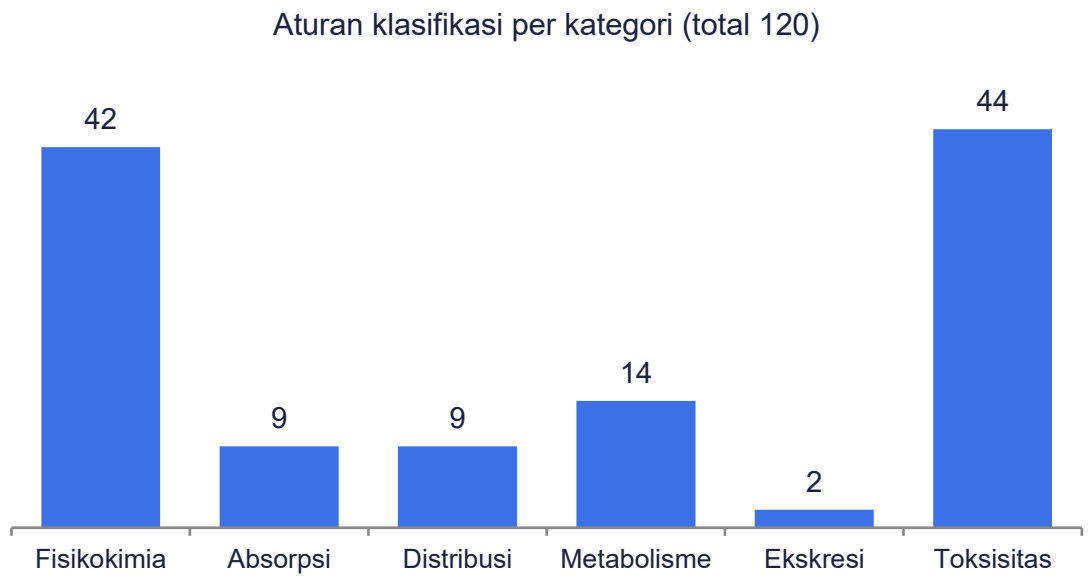
# ADMET: prediksi ADMETLab 3.0 langsung, atau dari file unduhan

**Jalur A: scraper ADMETLab 3.0**

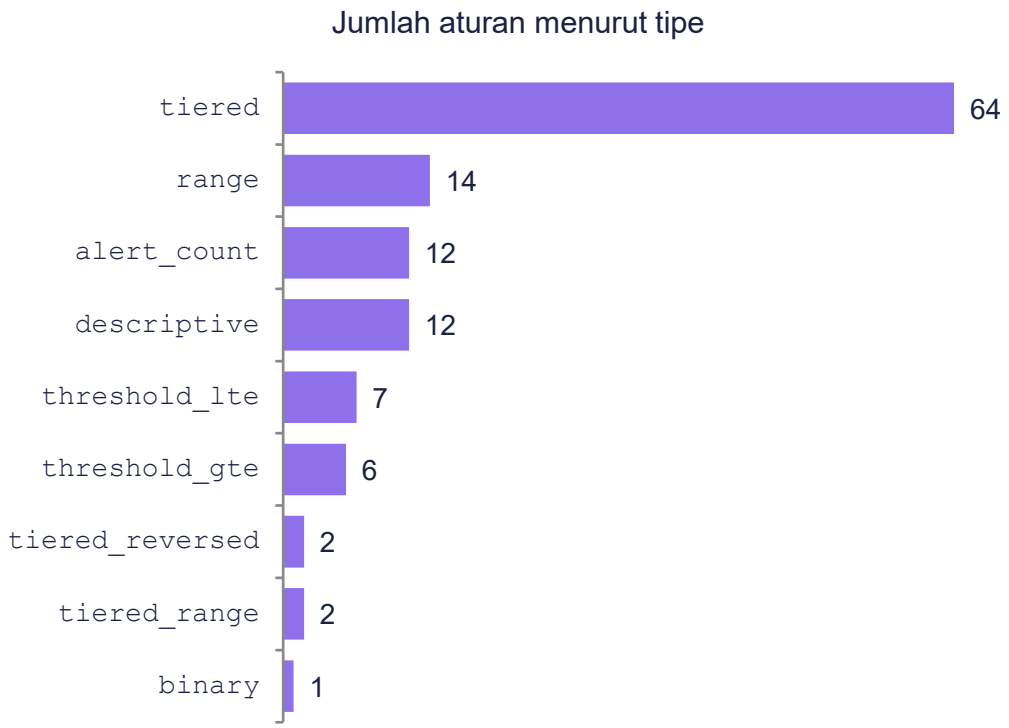
1. GET /server/screening, ambil token CSRF
2. POST /server/screeningCal: SMILES unik, batch ≤ 50 (maks 100)
3. Cari tautan /download/csv/ di halaman hasil
4. Unduh CSV; baris ke-N = SMILES unik ke-N, disalin ke ligan kembar
5. Retry 5×, jeda 10 dtk × percobaan, untuk 429/5xx/timeout
6. Baris tak cocok: dicocokkan lewat raw_smiles, atau batch dilewati

**Jalur B: --admet-file**

CSV atau XLSX (sheet pertama) hasil unduhan ADMETLab3. Baris ke-N adalah ligan ke-N di Excel ligan, atau SMILES unik ke-N bila ada senyawa kembar antar grup (baris disalin); jumlah baris harus sama dengan salah satunya. Bila ada kolom smiles, dicocokkan dengan SMILES ligan dan memberi peringatan bila beda.



# Satu tabel aturan mengubah 120 kolom ADMET menjadi lampu hijau, kuning, merah




Sumber: admet_rules.py. 108 aturan terskor dan 12 deskriptif.

| Kolom | Hijau | Kuning atau merah |
|---|---|---|
| MW | 100 sampai 600 Da | di luar rentang: merah |
| TPSA | 0 sampai 140 Å² | di luar rentang: merah |
| QED | > 0,67 | selain itu merah |
| Lipinski | ≤ 1 pelanggaran | selain itu merah |
| hERG, HIA, BBB | ≤ 0,3 | 0,3 sampai 0,7 kuning; > 0,7 merah |
| cl-plasma | ≤ 5 mL/min/kg | 5 sampai 15 kuning; > 15 merah |
| PAINS, BMS | tanpa peringatan | ada peringatan: merah |

```
skor kategori = rata-rata( hijau 1,0 · kuning 0,5 · merah 0,0 ),
atas aturan terskor yang bukan N/A
```

# Fisikokimia: Lipinski Rule of Five dihitung lokal dengan RDKit

```
mw   = Descriptors.MolWt(mol)
logp = Descriptors.MolLogP(mol)    # Crippen
hbd  = rdMolDescriptors.CalcNumLipinskiHBD(mol)
hba  = rdMolDescriptors.CalcNumLipinskiHBA(mol)

violations = sum([mw > 500, logp > 5, hbd > 5, hba > 10])
passes_ro5 = violations <= 1
```

descriptors.py:62-67 dan :33

- **Batas Lipinski (1997):** MW ≤ 500, logP ≤ 5, HBD ≤ 5, HBA ≤ 10; lolos bila pelanggaran ≤ 1
- **Dihitung pada mol ternetralkan** berhidrogen, tanpa perlu konformer 3D
- **Deskriptor tambahan** (TPSA, ikatan rotasi, cincin aromatik, Fsp3) ada di library tetapi belum dipakai pipeline
- **PCA, HCA, dan heatmap** memakai empat deskriptor ini: MW, LogP, HBD, HBA

| Ligan | MW | LogP | HBD | HBA | Pelanggaran |
|---|---|---|---|---|---|
| naproxen | 230,26 | 3,04 | 1 | 3 | 0 |
| paracetamol | 151,17 | 1,35 | 2 | 3 | 0 |
| omeprazole | 345,42 | 2,90 | 1 | 6 | 0 |
| aspirin | 180,16 | 1,31 | 1 | 4 | 0 |
| caffeine | 194,19 | 0,06 | 0 | 6 | 0 |
| luteolin | 286,24 | 2,13 | 4 | 6 | 0 |
| piperine | 285,34 | 3,00 | 0 | 4 | 0 |
| emodin | 270,24 | 1,89 | 3 | 5 | 0 |
| curcumin | 368,38 | 3,37 | 2 | 6 | 0 |
| berberine | 336,37 | 3,10 | 0 | 5 | 0 |

**Data demonstrasi**

Semua 10 ligan lolos Ro5 dengan 0 pelanggaran. Ro5 memprediksi potensi absorpsi oral, bukan aktivitas.

# Merge: pose terbaik dan reseptor bersih menjadi satu file kompleks




```
{
  "ligand_name": "curcumin",
  "ligand_code": "",
  "ligand_chain": "X",
  "ligand_resname": "CUR",
  "is_native": false
}
```

Sidecar nyata dari run demonstrasi

## Langkah merge_complex

- resName 3 karakter dari nama ligan; chain ligan = huruf bebas pertama, mundur dari X
- Atom ligan ditandai HETATM, residu 1, nama = unsur + indeks
- CombineMols dan satu konformer gabungan, disusun menurut posisi (bukan substruktur)
- TER disisipkan setelah blok reseptor dan blok ligan

## Mode dan referensi

- **best:** satu file per pasangan; pose dari replikat terbaik secara global
- **all:** <ligan>_repNN_modeMM_complex.pdb untuk setiap pose. Demo: 181 file per reseptor (180 pose + 1 native)
- **NATIVE_<label>_complex.pdb:** ligan kristal asli (bukan hasil docking) sebagai baseline similaritas

# Keluaran: folder terstruktur dan satu workbook Excel

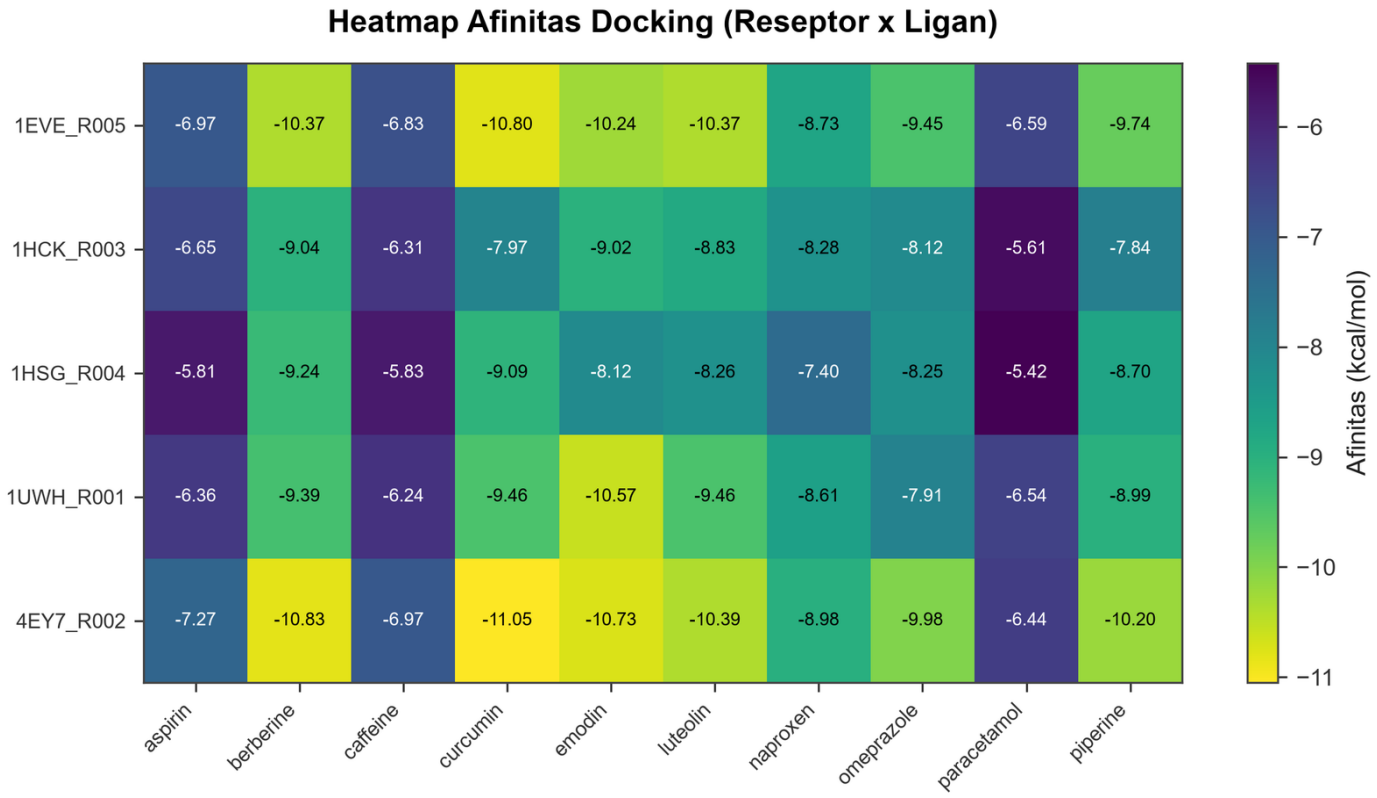
```
hasil/
├─ chemflow.log
├─ hasil_chemflow.xlsx
├─ ligands/<nama>/            2D.png · .pdb · .pdbqt
├─ receptors/<PDB>_R001/      _docking.pdbqt · _clean.pdb
├─ docking/<PDB>_R001/<ligan>/ repNN_out.pdbqt · repNN.log
│   (ligan native: NATIVE_<label>/, isi sama)
├─ complexes/<PDB>_R001/      <ligan>_complex.pdb + .json
├─ analytics/                 PNG (+ SVG, PDF)
├─ _state/                    config.json · progress.json ·
inputs/
└─ _cache/                    vina · ligand_templates
```

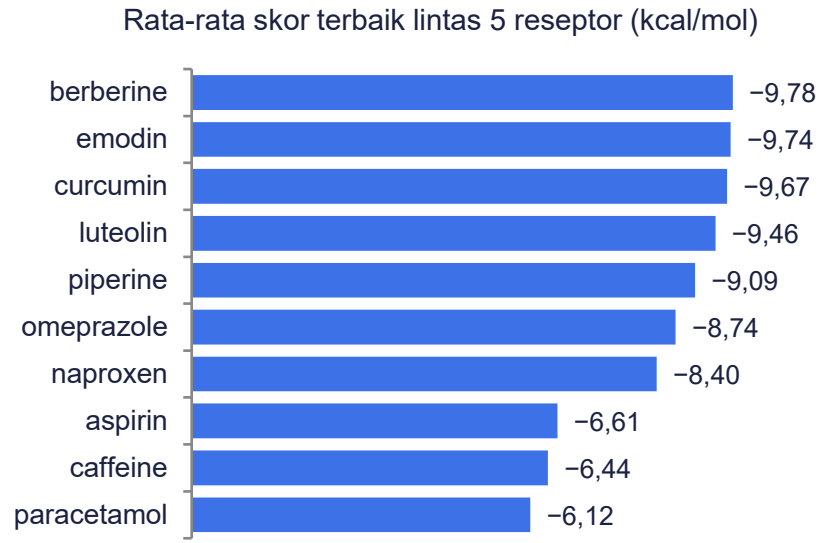
Kunci reseptor selalu <PDB>_R###, juga untuk satu situs (excel_receptors.py:46-49).

| Sheet | Baris × kolom | Isi |
|---|---|---|
| Ringkasan Ligan | 10 × 4 | nama, nama_file, smiles, group, status |
| Hasil Docking | 100 × 8 | satu baris per run: seed, skor, jumlah pose |
| Fisikokimia (Lipinski) | 10 × 7 | MW, LogP, HBD, HBA, pelanggaran |
| ADMET | 10 × 123 | kolom ADMETLab3, sel berwarna |
| Legenda ADMET | 120 × 7 | kategori, satuan, ambang, rujukan |
| Validasi RMSD | 5 × 7 | RMSD, status, skor redock, metode |
| Statistik Replikasi | 50 × 6 | rata-rata, simpangan baku, terbaik |

Baris data tanpa header, run demonstrasi. Sheet ditulis kondisional. Versi terbaru menambah kolom group, tipe, delta_vs_native, dan sheet per grup (lihat A5).

# Analitik 1: heatmap dan peringkat afinitas dari matriks docking



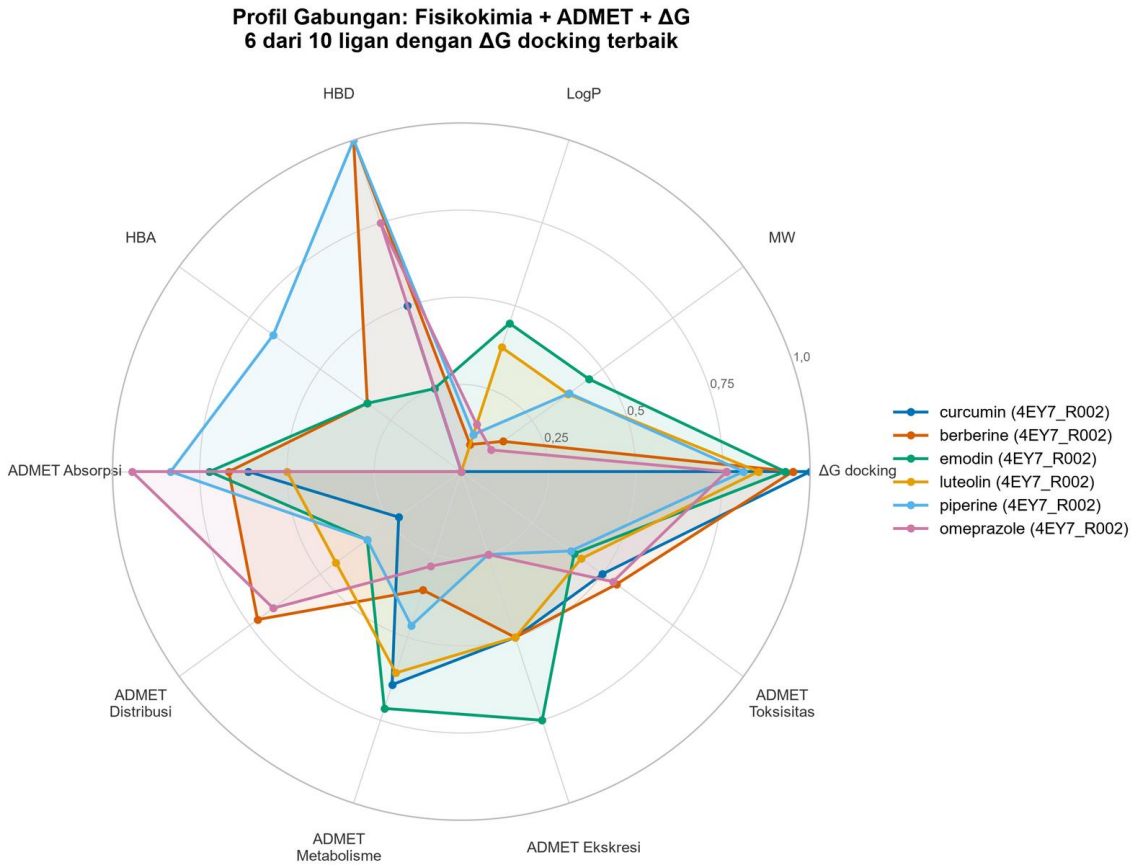




Keluaran chemflow: heatmap_afinitas.png. Data demonstrasi: skor Vina terbaik dari 2 replikat (kcal/mol). Estimasi skor, bukan afinitas eksperimen.

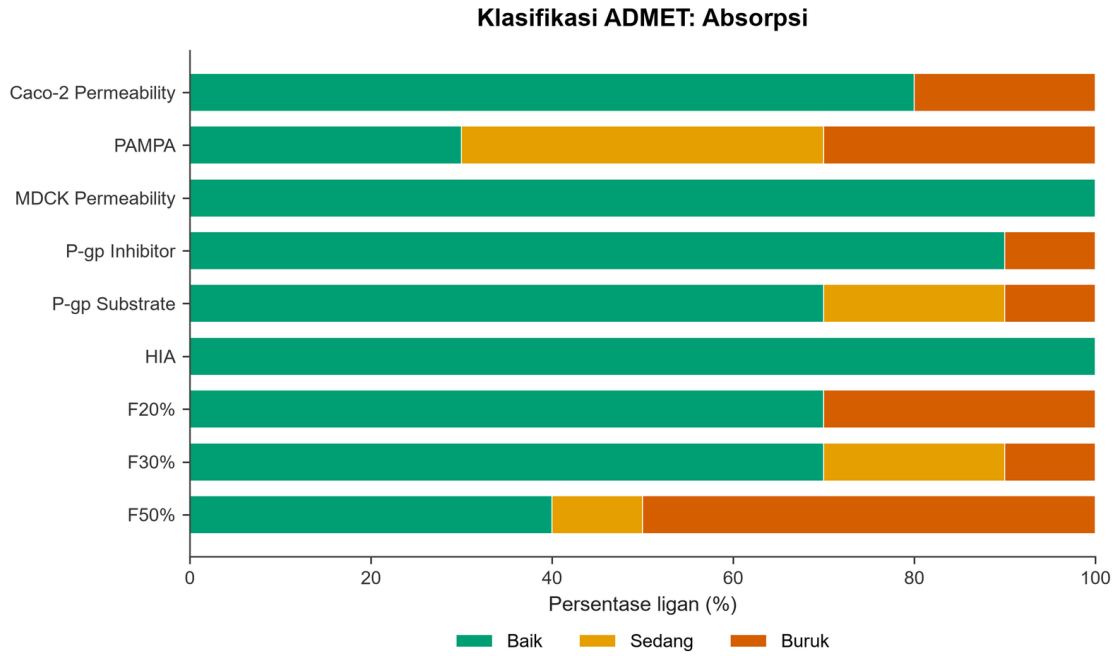
**Pasangan terbaik**

curcumin dengan 4EY7: −11,05 kcal/mol (rerata dua replikat −10,92 ± 0,13).

# Analitik 2: radar gabungan dan klasifikasi ADMET per kategori



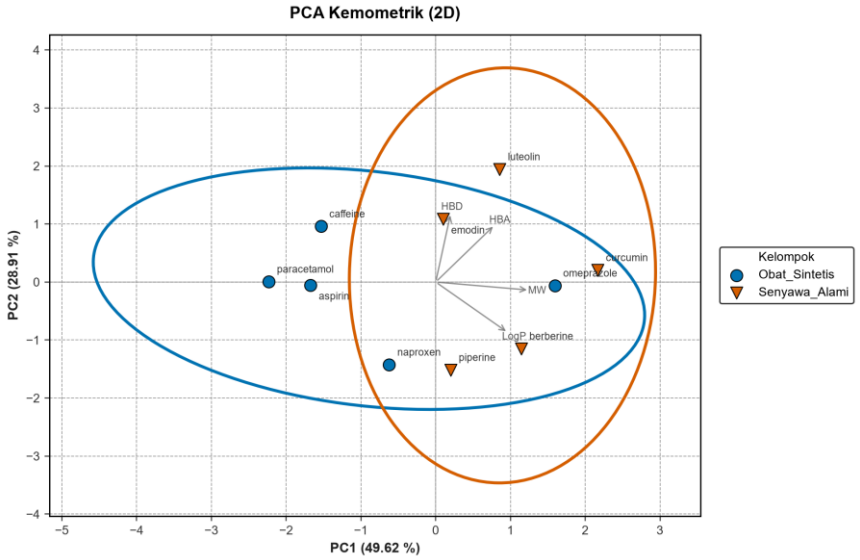

radar_combined.png (data demonstrasi). ΔG docking = skor Vina.

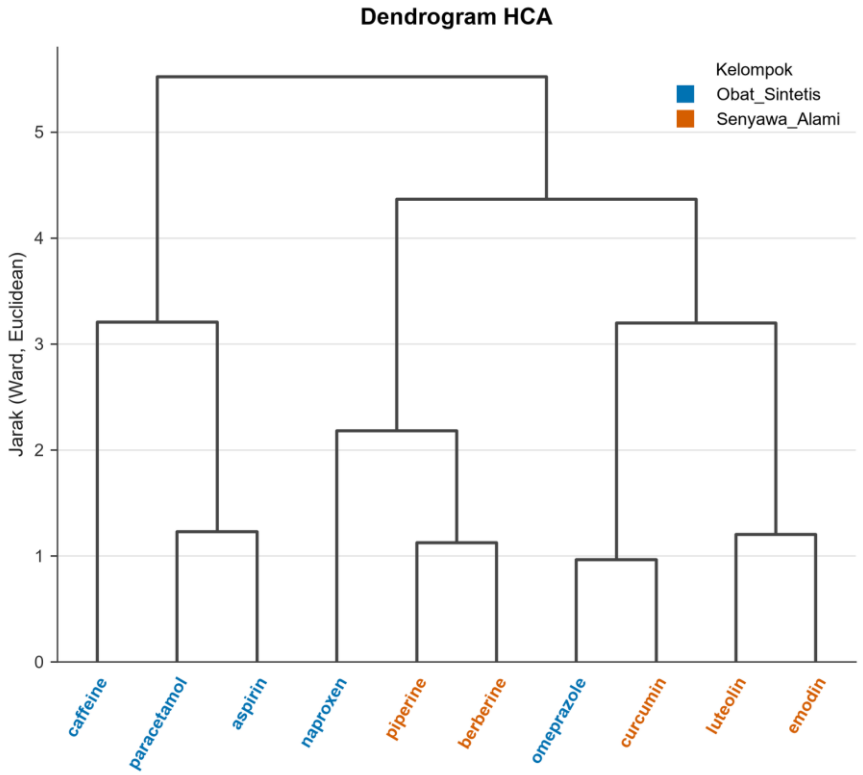



admet_klasifikasi_absorpsi.png (data demonstrasi, 10 ligan).

- **Radar:** ΔG, MW, LogP, HBD, HBA dibalik (kecil = lebih baik) + skor tiap kategori ADMET; min-max per kriteria; enam ligan terbaik pada reseptor terbaik masing-masing
- **Batang:** persentase ligan baik, sedang, buruk per parameter

# Analitik 3: PCA dan HCA membaca ruang kimia senyawa




pca_2d.png (gaya jurnal, dihitung ulang dari data demonstrasi) dan hca_dendrogram.png.

Klaster k = 3: {caffeine, paracetamol, aspirin}, {naproxen, piperine, berberine}, {omeprazole, luteolin, emodin, curcumin}.

## Cara baca

- Fitur: MW, LogP, HBD, HBA; z-score
- PCA: PC1 49,6%, PC2 28,9%, PC3 21,2%
- Elips 95% ($\chi^2$ 5,991) per kelompok, minimal 3 titik
- HCA: Ward, jarak Euclid
- Kedua kelompok sumber bercampur

*Empat deskriptor tidak memisahkan kelompok sumber.*

# Similaritas interaksi: kemiripan pola kontak dengan ligan native

1. **`chemflow run`**
   menghasilkan kompleks ligan dan NATIVE_*_complex.pdb

2. **`Otomatis lewat BIOVIA (Windows)`**
   Windows: tiap kompleks dibuka di GUI BIOVIA dengan input terkunci, diagram 2D dan tabel Non-bond diekspor sendiri; ekspor manual tetap bisa

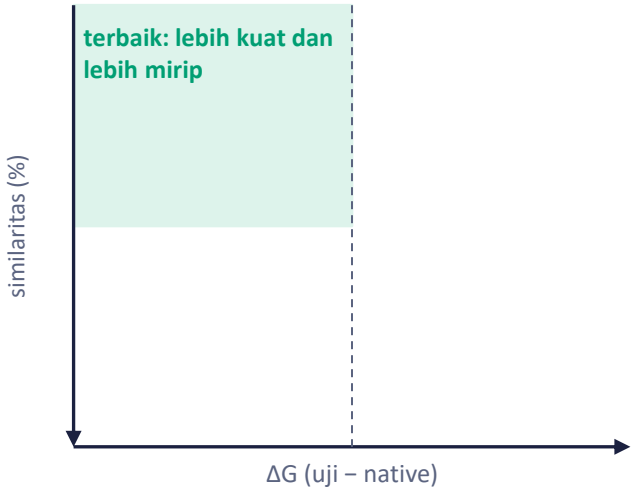
3. **`Simpan berkas interaksi`**
   interaksi/<PDB>_R001/<nama>_complex_interaksi.xlsx dan .png

4. **`chemflow similarity --output hasil/`**
   membaca interaksi protein-ligan; ligan uji vs native

5. **`Keluaran`**
   similaritas_interaksi.xlsx, similaritas_bar.png, similaritas_vs_deltag.png, similaritas_jejak_<reseptor>.png

$$\%sim = (0{,}5 \cdot nAAuji/nAAref + 0{,}5 \cdot intAAuji/intAAref) \times 100$$

nAA: residu yang berinteraksi dengan ligan uji dan ligan referensi. intAA: pasangan (residu, tipe interaksi) yang sama. ΔG = skor uji − skor referensi; negatif berarti lebih kuat dari native.




- Asimetris: mengukur cakupan kontak native, bukan Jaccard
- Kunci residu tanpa chain, jadi rantai kembar bisa menyatu
- ΔG referensi: terbaik-dari-n replikat native, seperti ligan uji

Diagram konsep tanpa data: run demonstrasi tidak memuat berkas interaksi BIOVIA. Metode: Pratama dkk. (2021).

# Gaya publikasi bawaan: aman buta warna, 300 dpi, PNG, SVG, PDF

## Palet kategorikal (analytics/style.py)

| #0072B2 | #D55E00 | #009E73 | #E69F00 | #56B4E9 |
|---|---|---|---|---|
| #CC79A7 | #F0E442 | #000000 | #999999 | #66C2A5 |

## Semantik kualitas

baik | sedang | buruk | netral

Okabe dan Ito (2008). Palet ke-10 (#66C2A5) tambahan dari chemflow.

### 300 dpi, tiga format

--dpi dan --figure-formats png svg pdf; PNG selalu ditulis

### Teks tetap teks

svg.fonttype none dan pdf.fonttype 42 agar bisa disunting di Illustrator atau Inkscape

### Tidak mengubah global

Gaya lewat rc_context, jadi rcParams matplotlib pemanggil utuh

### Label tanpa tumpang tindih

annotate_without_overlap mencoba beberapa posisi label

### Teks grafik berbahasa Indonesia

Judul dan sumbu ditulis langsung di kode; naskah Inggris perlu render ulang

# Instalasi dan cek kesiapan dalam lima menit

**1** **Pasang dependensi Python**

```
pip install -r requirements.txt
pip install -e .
```

**2** **Pasang OpenBabel (contoh via conda)**

```
conda create -n chemflow_tools \
  -c conda-forge openbabel -y
```

**3** **Cek kesiapan dan buat templat**

```
python -m chemflow init --output contoh/
```

**Yang perlu dicermati**

Tanda !! berarti perlu perhatian. v2.1.0 mencari cache, PATH, dan lokasi instalasi umum. Path manual cukup diberikan sekali. Vina tidak perlu dipasang: diunduh otomatis.

```
=== Pemeriksaan Kesiapan Mesin chemflow ===

[Python]
  OK  Versi interpreter: 3.14.6 (OK)
[Paket Python]
  OK  rdkit: terpasang (v2026.03.5)
  OK  pandas: terpasang (v3.0.5)
  OK  openpyxl: terpasang (v3.1.5)
  ... (9 paket diperiksa)
[Tool eksternal]
  !!  OpenBabel: tidak ditemukan di PATH
[AutoDock Vina]
  OK  GitHub Releases: 5 versi kompatibel
      tersedia: 1.2.7, 1.2.6, 1.2.5, 1.2.4, 1.2.3
[Jaringan]
  OK  RCSB (unduh struktur PDB): terjangkau
  OK  PubChem (resolusi SMILES): terjangkau
  OK  ADMETLab3 (prediksi ADMET): terjangkau
  OK  GitHub Releases (auto-download Vina): terjangkau

1 hal butuh perhatian (lihat tanda '!!' di atas).
```

Arsip keluaran init versi sebelumnya (dipotong).

D · PRAKTIK

# Menjalankan chemflow: dari gridbox sampai similaritas

```
# 1. susun reseptor.xlsx secara interaktif
python -m chemflow receptor-config
```

```
# 2. pipeline penuh (contoh perintah)
python -m chemflow run \
  --ligands ligan.xlsx \
  --receptors reseptor.xlsx \
  --output hasil/ \
  --run-rmsd-validation \
  --n-replicates 2 --exhaustiveness 16
```

```
# 3. lanjutkan run yang terhenti
python -m chemflow resume --output hasil/
```

```
# 4. opsional: interaksi BIOVIA, similaritas, dan GC-MS
python -m chemflow interactions --output hasil/
python -m chemflow similarity --output hasil/
python -m chemflow gcms --data data-gcms/ --output hasil/
```

Progress bar (tqdm) tampil di tiap tahap panjang; --no-progress mematikannya.

**Cuplikan chemflow.log run demonstrasi (path dipendekkan)**

```
23:22:31 === chemflow: memulai pipeline ===
23:22:31 [Ligan] Mode TIDY: nama='name', smiles='smiles', group='group'
23:22:31 [Ligan] 10 senyawa dimuat (10 perlu resolusi PubChem, 2
kelompok terdeteksi).
23:22:31 Resolusi PubChem untuk 10 senyawa tanpa SMILES ...
23:22:42 [PubChem] 'curcumin' ->
COC1=C(C=CC(=C1)/C=C/C(=O)CC(=O)/C=C/C2=CC(=C(C=C2)O)OC)O
23:22:43 Ligan siap docking: 10/10
23:22:52 ADMET diperoleh untuk 10/10 senyawa.
23:22:52 Mengunduh Vina 1.2.7 (windows/x86_64) dari GitHub Releases
23:22:53 [Reseptor] Kolom gridbox ditemukan: center_x, center_y,
center_z
23:23:01 Reseptor siap docking: 5/5
23:23:01 [1/100] Docking 'naproxen' -> '1UWH_R001' (replikat 1/2)
23:23:04 Vina selesai: 9 pose, afinitas terbaik=-8.607 kcal/mol
23:31:14 [100/100] Docking 'berberine' -> '1EVE_R005' (replikat 2/2)
23:35:12 Hasil diekspor ke: hasil_chemflow.xlsx
23:35:28 PCA kemometrik berhasil dibuat.
23:35:29 === chemflow: pipeline selesai ===
```

# Cheat-sheet opsi dan pemecahan masalah umum

## Opsi penting chemflow run

| Opsi | Fungsi |
|---|---|
| `--run-rmsd-validation` | Hitung RMSD in place ligan native (native selalu di-dock) |
| `--n-replicates N` | Ulangi tiap docking N kali, seed berbeda |
| `--no-native` | Jangan dock ligan native (tanpa pembanding) |
| `--box-padding N` | Padding gridbox dari ukuran native (bawaan 8 Å) |
| `--exhaustiveness N` | Ketelitian pencarian Vina (bawaan 8) |
| `--seed N` | Seed dasar; replikat = seed + n − 1 |
| `--merge-mode best\|all` | Satu pose terbaik atau semua pose |
| `--admet-file f` | Pakai file ADMETLab3 (.csv, .xlsx) |
| `--no-admet` | Lewati ADMET |
| `--openbabel-path p` | Lokasi obabel bila tak ada di PATH |
| `--no-interactive-gridbox` | Larang prompt; gridbox wajib di Excel |
| `--dpi, --figure-formats` | Resolusi dan format grafik |
| `--keep-waters` | Efektif hanya bersama --keep-hetero-ligands (perilaku kode saat ini) |

## Gejala dan solusi

| Gejala | Penyebab dan solusi |
|---|---|
| Executable 'obabel' tidak ditemukan | Pasang OpenBabel atau pakai --openbabel-path |
| SMILES tidak ditemukan di PubChem | Isi kolom smiles, atau pakai nama internasional |
| ADMETLab3 429 atau timeout | Retry otomatis; lanjut --admet-file atau --no-admet |
| Jumlah baris file ADMET berbeda | Jumlah baris = ligan atau SMILES unik; urutan sama dengan Excel ligan |
| Proses berhenti menunggu | Pilih ligan native, atau isi gridbox / --no-interactive-gridbox |
| PCA atau HCA dilewati | Kolom group perlu minimal 2 nilai |
| Gagal mengunduh PDB | Kode salah, atau struktur hanya tersedia sebagai mmCIF |
| Path terlalu panjang (Windows) | Pilih folder output lebih pendek |
| Run terhenti di tengah | chemflow resume --output hasil/ (lanjut dari checkpoint) |
| Grafik terpecah _part01of03 | Wajar bila ligan atau reseptor banyak; atur --plot-max-rows/cols (0 = satu gambar) |

D · PRAKTIK

# Library Python: pipeline penuh atau komponen tunggal

### Pipeline penuh

```
from chemflow import Pipeline, PipelineConfig

config = PipelineConfig(
    ligand_excel="ligan.xlsx",
    receptor_excel="reseptor.xlsx",
    output_dir="hasil",
    exhaustiveness=16,
    n_replicates=2,
    run_rmsd_validation=True,
)
exit_code = Pipeline(config).run()    # 0 selesai, 1 fatal
# 130 bila Ctrl+C. Lanjutkan dengan:
Pipeline(config, resume=True).run()
```

### Komponen tunggal

```
from rdkit import Chem
from chemflow import LipinskiCalculator, classify_admet_value

mol = Chem.MolFromSmiles("CC(=O)OC1=CC=CC=C1C(=O)O")
r = LipinskiCalculator.calculate(mol)
print(r.molecular_weight, r.violations, r.passes_ro5)

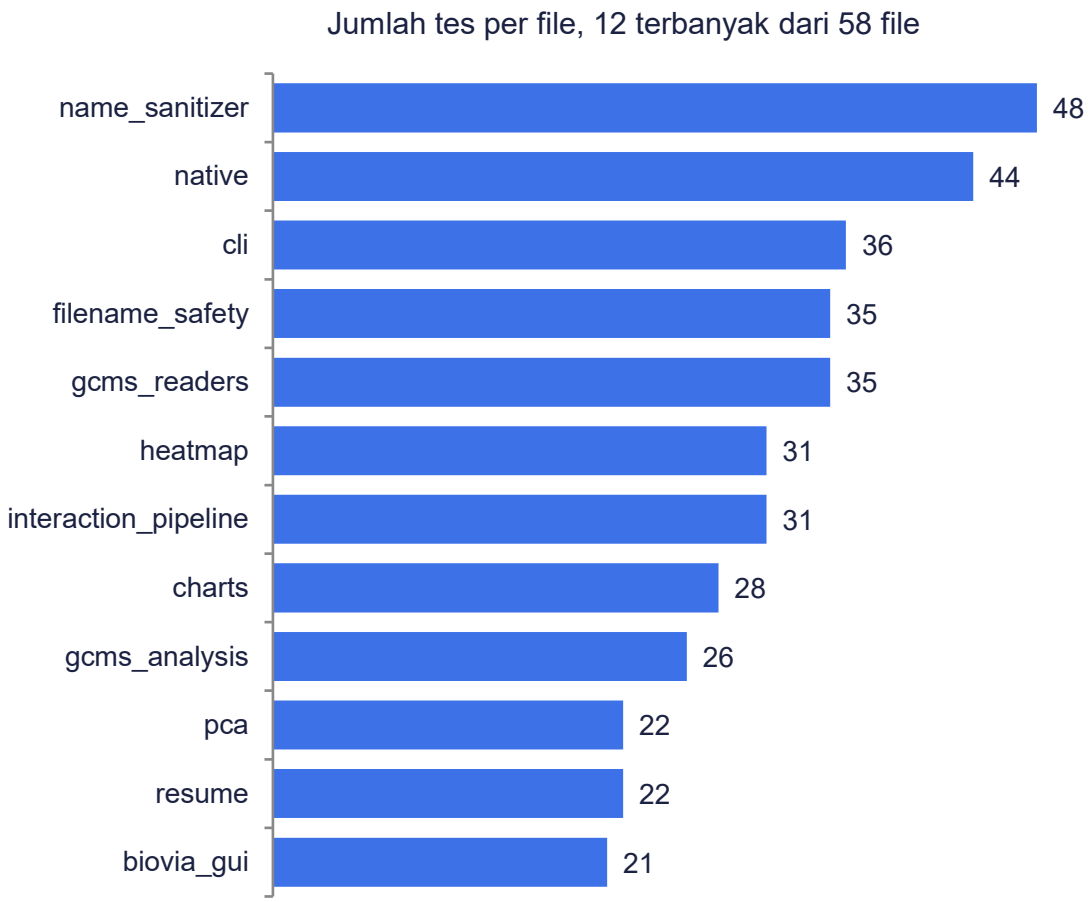
classify_admet_value("hERG", 0.82).flag   # Flag.RED
```

64 nama publik diekspor dari chemflow/__init__.py, antara lain:

LigandPreparer · ReceptorPreparer · OpenBabelConverter · VinaReleaseManager · VinaRunner · GridBox · ChartBuilder · HeatmapBuilder · ChemometricPCA · HierarchicalClustering · SimilarityAnalyzer · run_gcms_analysis

Catatan: run() mengembalikan 0 walau tidak ada pasangan yang berhasil di-docking. Periksa log atau pipeline.failed_ligands dan failed_receptors.

# Arsip v2.0: 832 tes unit berjalan ±76 detik tanpa jaringan




**832**
tes lulus

**58**
file tes

**75,7 dtk**
waktu total

- **Sandbox:** OpenBabel, Vina, dan jaringan diganti kelas palsu atau monkeypatch (mis. _FakeVinaRunner)
- **Injeksi dependensi** membuat modul bisa dites terpisah: runner, converter, dan I/O interaktif disuntik
- **Lingkungan:** Python 3.14.6, pytest 9.1.1

E · PENUTUP

# Keterbatasan ilmiah sebelum menafsirkan hasil

### RMSD in place bersifat ketat

RMSD in place mengukur ketepatan posisi, jadi ketat untuk ligan besar dan fleksibel: 1HSG 10,52 Å (4,04 Å bila diselaraskan dulu).

### Skor Vina bukan afinitas eksperimen

Estimasi empiris (kcal/mol) dengan kecenderungan terhadap ukuran ligan. Validasi eksperimen tetap diperlukan.

### Reseptor kaku dan model sederhana

Rigid, tanpa air, tanpa model protonasi (His menjadi HIE, gugus asam dan basa netral); muatan parsial hanya sebagian tercakup.

### ADMET adalah prediksi model

Keluaran ADMETLab 3.0, bukan pengukuran. Pita 0,3/0,7 generik untuk sekitar 64 endpoint adalah asumsi.

### Similaritas interaksi

Asimetris, kunci residu tanpa chain. Ekspor BIOVIA otomatis hanya di Windows; mouse dan keyboard dikunci selama ekspor.

### Ruang kimia sempit

PCA dan HCA hanya memakai MW, LogP, HBD, HBA. Tanpa dinamika molekul atau perhitungan energi bebas.

**Saran pelaporan**

Catat versi Vina, exhaustiveness, seed, replikat, gridbox, dan padding; sebutkan RMSD dihitung in place; tulis bahwa skor adalah estimasi komputasi.

# Keterbatasan teknis dan keamanan yang perlu dijaga saat dipakai

### ADMETLab3 lewat scraping

Verifikasi TLS mati secara bawaan (--admet-ssl-verify untuk mengaktifkan). SMILES dikirim ke server pihak ketiga; ketentuan layanan belum ditinjau. Untuk jalur aman, pakai file unduhan.

### Biner Vina tanpa checksum

Diunduh dari GitHub Releases dan dijalankan tanpa verifikasi checksum atau tanda tangan. Cache per folder output.

### Serial, resume tersedia

Satu proses berurutan tanpa batas waktu subprocess; hasil per item tersimpan, jadi chemflow resume melanjutkan. --cpu tidak terekspos di CLI.

### Kode keluar dan galat

run() bernilai 0 walau tidak ada yang berhasil di-docking. Galat konfigurasi muncul sebagai traceback.

### Input terbatas

Hanya .pdb dari RCSB (bukan mmCIF) dan Excel .xlsx. Kolom PDBQT reseptor berlebih bila serial melewati 99.999.

### Windows dan library

Batas path 260 karakter: nama file ligan dipendekkan otomatis. Mengimpor chemflow memaksa backend Agg matplotlib.

# Referensi


**1.** Lipinski CA, Lombardo F, Dominy BW, Feeney PJ. Experimental and computational approaches to estimate solubility and permeability in drug discovery and development settings. Adv Drug Deliv Rev. 1997;23:3-25.

**2.** Trott O, Olson AJ. AutoDock Vina: improving the speed and accuracy of docking with a new scoring function, efficient optimization, and multithreading. J Comput Chem. 2010;31(2):455-461. doi:10.1002/jcc.21334

**3.** Eberhardt J, Santos-Martins D, Tillack AF, Forli S. AutoDock Vina 1.2.0: new docking methods, expanded force field, and Python bindings. J Chem Inf Model. 2021;61(8):3891-3898. doi:10.1021/acs.jcim.1c00203

**4.** Morris GM, Huey R, Lindstrom W, et al. AutoDock4 and AutoDockTools4: automated docking with selective receptor flexibility. J Comput Chem. 2009;30:2785-2791. doi:10.1002/jcc.21256

**5.** Fu L, Shi S, Yi J, et al. ADMETlab 3.0: an updated comprehensive online ADMET prediction platform enhanced with broader coverage, improved performance, API functionality and decision support. Nucleic Acids Res. 2024;52(W1):W422-W431. doi:10.1093/nar/gkae236

**6.** Xiong G, Wu Z, Yi J, et al. ADMETlab 2.0: an integrated online platform for accurate and comprehensive predictions of ADMET properties. Nucleic Acids Res. 2021;49(W1):W5-W14. doi:10.1093/nar/gkab255

**7.** Hevener KE, Zhao W, Ball DM, et al. Validation of molecular docking programs for virtual screening against dihydropteroate synthase. J Chem Inf Model. 2009;49(2):444-460. doi:10.1021/ci800293n

**8.** Pratama MRF, Poerwono H, Siswodihardjo S. Introducing a two-dimensional graph of docking score difference vs. similarity of ligand-receptor interactions. Indones J Biotechnol. 2021;26(1):54-60. doi:10.22146/ijbiotech.62194

**9.** Cornell WD, Cieplak P, Bayly CI, et al. A second generation force field for the simulation of proteins, nucleic acids, and organic molecules. J Am Chem Soc. 1995;117:5179-5197. doi:10.1021/ja00124a002

**10.** O'Boyle NM, Banck M, James CA, et al. Open Babel: an open chemical toolbox. J Cheminform. 2011;3:33. doi:10.1186/1758-2946-3-33

**11.** Okabe M, Ito K. Color Universal Design (CUD): how to make figures and presentations that are friendly to colorblind people. 2008.

**12.** Landrum G. RDKit: open-source cheminformatics. https://www.rdkit.org

E · PENUTUP

# Kesimpulan: dari dua Excel ke hasil yang dapat diuji ulang

1. Pipeline in silico dapat diotomasi dari dua file Excel dengan Python, RDKit, OpenBabel, dan AutoDock Vina.
2. Validasi redocking dan ADMET memberi konteks, tetapi skor docking tetap estimasi.
3. Keluaran siap publikasi: Excel berwarna, grafik 300 dpi, kompleks PDB.
4. Baca hasil secara kritis: tinjau RMSD, replikat, dan asumsi sebelum menyimpulkan.

## Tanya jawab

Arif Maulana Azis · github.com/Arifmaulanaazis/chemflow · Lisensi MIT

APPENDIX

# Ambang ADMET (1/2): aturan dengan batas numerik

## Fisikokimia (aturan numerik; alert dan tiered di A2)

| Kolom | Parameter | Hijau bila |
|---|---|---|
| MW | Molecular Weight (Da) | 100 s.d. 600 |
| nHA | H-Bond Acceptors | 0 s.d. 12 |
| nHD | H-Bond Donors | 0 s.d. 7 |
| TPSA | TPSA (Å²) | 0 s.d. 140 |
| nRot | Rotatable Bonds | 0 s.d. 11 |
| nRing | Ring Count | 0 s.d. 6 |
| MaxRing | Max Ring Size (atoms) | 0 s.d. 18 |
| nHet | Heteroatom Count | 1 s.d. 15 |
| fChar | Formal Charge | −4 s.d. 4 |
| nRig | Rigid Bonds | 0 s.d. 30 |
| nStereo | Stereo Centers | ≤ 2 |
| logS | logS (log mol/L) | −4 s.d. 0,5 |
| logP | logP (log mol/L) | 0 s.d. 3 |
| logD | logD 7.4 (log mol/L) | 1 s.d. 3 |
| QED | QED | > 0,67 |
| Synth | SAscore (1-10) | < 6 |
| gasa | GASA (0/1) | 0 |
| Fsp3 | Fsp3 | ≥ 0,42 |
| MCE-18 | MCE-18 | ≥ 45 |
| Lipinski | Lipinski Rule (pelanggaran) | ≤ 1 |
| Pfizer | Pfizer Rule (pelanggaran) | ≤ 1 |
| GSK | GSK Rule (pelanggaran) | ≤ 0 |
| GoldenTriangle | Golden Triangle (pelanggaran) | ≤ 0 |

## Absorpsi, Distribusi, Ekskresi

| Kolom | Parameter | Hijau bila |
|---|---|---|
| caco2 | Caco-2 Permeability (log cm/s) | > −5,15 |
| MDCK | MDCK Permeability (log cm/s) | ≥ −5,7 |
| PPB | Plasma Protein Binding (%) | ≤ 90 |
| VDss | VDss (log10(L/kg)) | −1,4 s.d. 1,3 |
| Fu | Fraction Unbound (%) | ≥ 5 |
| cl-plasma | Plasma Clearance (mL/min/kg) | ≤ 5 hijau / 5-15 kuning / > 15 merah |
| t0.5 | Half-life (jam) | > 8 hijau / 1-8 kuning / < 1 merah |

**Cara baca**

Di luar batas hijau berarti merah, kecuali tipe tiered_range (Ekskresi) yang punya pita kuning. Batas strik (>, <) di kode ditulis dengan toleransi 1e-9. Sumber: admet_rules.py.

APPENDIX

# Ambang ADMET (2/2): kelompok probabilitas dan peringatan

| Kategori | Tipe | Kolom |
|---|---|---|
| Fisikokimia | tiered: ≤ 0,3 hijau, ≤ 0,7 kuning, > 0,7 merah | Aggregators, Fluc, Blue_fluorescence, Green_fluorescence, Reactive, Promiscuous, Other_assay_interference |
| Fisikokimia | alert: tanpa peringatan hijau, ada peringatan merah | Alarm_NMR, BMS, Chelating, PAINS |
| Fisikokimia | deskriptif: tanpa ambang | Vol, Dense, Flex, mp, bp, pka_acidic, pka_basic, Natural Product-likeness |
| Absorpsi | tiered: ≤ 0,3 hijau, ≤ 0,7 kuning, > 0,7 merah | PAMPA, pgp_inh, pgp_sub, hia, f20, f30, f50 |
| Distribusi | tiered: ≤ 0,3 hijau, ≤ 0,7 kuning, > 0,7 merah | OATP1B1, OATP1B3, BSEP, MRP1, BBB |
| Distribusi | tiered terbalik: ≤ 0,3 merah, ≤ 0,7 kuning, > 0,7 hijau | BCRP |
| Metabolisme | tiered: ≤ 0,3 hijau, ≤ 0,7 kuning, > 0,7 merah | CYP1A2-inh, CYP1A2-sub, CYP2C19-inh, CYP2C19-sub, CYP2C9-inh, CYP2C9-sub, CYP2D6-inh, CYP2D6-sub, CYP3A4-inh, CYP3A4-sub, CYP2B6-inh, CYP2B6-sub, CYP2C8-inh |
| Metabolisme | tiered terbalik: ≤ 0,3 merah, ≤ 0,7 kuning, > 0,7 hijau | LM-human |
| Toksisitas | tiered: ≤ 0,3 hijau, ≤ 0,7 kuning, > 0,7 merah | Neurotoxicity-DI, Ototoxicity, Hematotoxicity, Nephrotoxicity-DI, Genotoxicity, RPMI-8226, A549, HEK293, hERG-10um, hERG, H-HT, DILI, Ames, ROA, FDAMDD, SkinSen, Carcinogenicity, EC, EI, Respiratory, NR-AhR, NR-AR, NR-AR-LBD, NR-Aromatase, NR-ER, NR-ER-LBD, NR-PPAR-gamma, SR-ARE, SR-ATAD5, SR-HSE, SR-MMP, SR-p53 |
| Toksisitas | alert: tanpa peringatan hijau, ada peringatan merah | LD50_oral, NonBiodegradable, NonGenotoxic_Carcinogenicity, SureChEMBL, Skin_Sensitization, Acute_Aquatic_Toxicity, Genotoxic_Carcinogenicity_Mutagenicity, FAF-Drugs4 Rule |
| Toksisitas | deskriptif: tanpa ambang | BCF, IGC50, LC50DM, LC50FM |

APPENDIX

# Semua opsi chemflow run (bawaan dalam kurung)

| Grup | Opsi |
|---|---|
| Input | --receptors wajib; --ligands wajib kecuali --rmsd-only; --output (chemflow_output) |
| Kolom Excel | --ligand-name-col, --ligand-smiles-col, --ligand-group-col, --receptor-pdb-col (otomatis) |
| Gridbox | --default-box-size (20.0, hanya cadangan); --box-padding (8.0); --no-interactive-gridbox |
| Preparasi ligan | --force-field {MMFF94, UFF} (MMFF94); --minimize-max-iters (1000); --no-2d-image |
| Preparasi reseptor | --keep-waters; --keep-hetero-ligands; --no-keep-metals; --kollman-fallback {zero, gasteiger} (zero) |
| Docking | --vina-version; --vina-executable; --exhaustiveness (8); --num-modes (9); --energy-range (3.0); --seed (acak); --n-replicates (1) |
| Merge | --merge-mode {best, all} (best) |

| Grup | Opsi |
|---|---|
| Native dan RMSD | --no-native; --run-rmsd-validation; --rmsd-only; opsi best/all terpisah (lihat A12) |
| Interaksi BIOVIA | --similarity / --no-similarity (otomatis bila terdeteksi); --biovia-exe (otomatis); --biovia-timeout (90); --no-lock-input |
| OpenBabel | --openbabel-path (disimpan per pengguna) |
| ADMET | --no-admet; --admet-file; --admet-batch-size (50); --admet-ssl-verify |
| PubChem | --no-pubchem-fetch; --no-pubchem-interactive-fallback |
| Analitik | --no-charts; --no-pca; --no-hca; --no-heatmap; --dpi (300); --figure-formats {png, svg, pdf} (png); --plot-max-rows (30); --plot-max-cols (20) |
| GC-MS (opsional) | --gcms PATH...; --gcms-groups; --gcms-library |
| Logging | --verbose (tanpa efek saat ini); --log-level (INFO); --no-progress |
| Subperintah lain | init; resume --output DIR [--biovia-exe ...]; receptor-config; list-vina-versions; interactions --output DIR [--receptor --force --biovia-exe --biovia-timeout --no-lock-input]; similarity --output DIR [--interactions-dir --result-filename --no-plots --dpi]; gcms --output DIR [--data --groups --library --alkanes --scaling --normalization --permutations --no-plots] |

APPENDIX

# Format PDBQT: reseptor datar, ligan dengan pohon torsi

### Reseptor (4EY7_R002, 10.028 atom): 9 baris pertama

```
REMARK  Reseptor rigid, ditulis oleh chemflow.chem.pdbqt_writer
ATOM      1 N    GLU A   4       2.514 -35.401  69.696  1.00  0.00    -0.416 NA
ATOM      2 CA   GLU A   4       2.230 -35.193  68.280  1.00  0.00     0.034 C
ATOM      3 C    GLU A   4       3.436 -35.566  67.408  1.00  0.00     0.597 C
ATOM      4 O    GLU A   4       4.572 -35.606  67.889  1.00  0.00    -0.568 OA
ATOM      5 CB   GLU A   4       1.808 -33.745  68.027  1.00  0.00     0.000 C
ATOM      6 CG   GLU A   4       1.007 -33.544  66.749  1.00  0.00     0.000 C
ATOM      7 CD   GLU A   4       0.729 -32.081  66.462  1.00  0.00     0.805 C
ATOM      8 OE1  GLU A   4       1.240 -31.222  67.218  1.00  0.00    -0.819 OA
```

### Ligan (curcumin): cuplikan

```
REMARK  12 active torsions:
ROOT
ATOM      1  C11 UNL     1      -0.715  -0.229  -2.653  1.00  0.00    +0.000 C
ENDROOT
BRANCH   1   2
ATOM      2  C10 UNL     1       0.550  -0.854  -2.134  1.00  0.00    +0.000 C
ATOM      3  O2  UNL     1       0.606  -2.063  -1.900  1.00  0.00    +0.000 OA
BRANCH   2   5
ATOM      4  C8  UNL     1       1.794   1.314  -1.914  1.00  0.00    +0.000 C
ATOM      5  C9  UNL     1       1.758  -0.026  -1.868  1.00  0.00    +0.000 C
...
ENDBRANCH   1  16
TORSDOF 10
```

- **Kolom:** record PDB standar, lalu occupancy 1,00, B 0,00, muatan parsial (6 lebar), tipe AD4 (2 lebar)
- **Reseptor:** datar tanpa ROOT/BRANCH, TER per rantai. Ditulis chemflow, bukan OpenBabel, agar muatan tidak tertimpa
- **Ligan:** OpenBabel menulis REMARK torsi aktif, ROOT/ENDROOT, BRANCH/ENDBRANCH, dan TORSDOF
- **Tipe AD4 umum:** C, A, N, NA, OA, SA, HD, H
- **Run demonstrasi:** ligan versi lama bermuatan 0,000 (10 dari 10); versi sekarang menulis muatan Gasteiger. Reseptor tercakup tabel muatan sebagian

APPENDIX

# Skema kolom setiap sheet hasil_chemflow.xlsx

| Sheet | Kolom |
|---|---|
| **Ringkasan Ligan** | `name, nama_file, smiles, group, tipe (uji atau native), status` |
| **Hasil Docking** | `ligand, group, receptor, replicate, seed, affinity_best, n_poses, status, error` |
| **Fisikokimia (Lipinski)** | `ligand, group, MW, LogP, HBD, HBA, Lipinski_Violations, Lolos_Ro5` |
| **ADMET** | `ligand, group, raw_smiles, smiles, lalu 120 kolom parameter ADMETLab3 berurutan per kategori (MW, Vol, Dense, ...)` |
| **Legenda ADMET** | `Kategori, Kolom, Label, Satuan, Ambang, Rujukan, Catatan` |
| **Validasi RMSD** | `receptor, native_ligand, rmsd_angstrom, status, redock_affinity, metode, catatan` |
| **Statistik Replikasi** | `ligand, group, receptor, n_replicates_success, affinity_mean, affinity_std, affinity_best, delta_vs_native` |
| **Ringkasan per Grup** | `grup, n_ligan, lolos_Ro5_persen, MW_rata2, LogP_rata2, HBD_rata2, HBA_rata2, ADMET_<kategori>` |
| **Docking per Grup** | `reseptor, grup, n_ligan, dG_rata2, dG_sd, dG_terbaik, dG_native` |

Nama kolom mengikuti versi terbaru; run demonstrasi lama belum memuat group, tipe, delta_vs_native, dan dua sheet per grup. Sheet ADMET diwarnai per sel menurut tabel aturan; header diwarnai per kategori.

APPENDIX

# Modul dan tanggung jawabnya

| Modul | Tanggung jawab |
|---|---|
| pipeline.py | Orkestrasi 12 tahap, fail-soft, resume |
| cli.py | argparse: init, run, resume, receptor-config, interactions, similarity, gcms |
| config.py | PipelineConfig tervalidasi, to_dict/from_dict |
| state.py, checkpoints.py | Folder _state dan checkpoint atomik untuk resume |
| chem/ligand_preparer | SMILES ke PDB/PDBQT |
| chem/receptor_preparer | Bersihkan, H polar, dua keluaran |
| chem/kollman_charges | Muatan parsial (tabel AMBER) |
| chem/atom_typing | Tipe atom AutoDock4 |
| chem/pdbqt_writer | PDBQT reseptor datar |
| chem/mol_converter | Pembungkus OpenBabel, muatan Gasteiger |
| chem/pubchem_client | SMILES dari nama |
| chem/descriptors | Lipinski dan deskriptor tambahan |
| io/excel_ligands, excel_receptors | Baca Excel (tidy, wide, gridbox) |
| io/pdb_fetcher | Unduh RCSB, ligan native |
| io/receptor_config | Excel reseptor interaktif |
| io/ligand_template | SMILES templat CCD RCSB |
| io/pdbqt_reader, result_exporter | Baca pose; tulis Excel berwarna |
| interaction/* | Ekspor interaksi lewat GUI BIOVIA (Windows), kunci input |

| Modul | Tanggung jawab |
|---|---|
| docking/vina_manager, vina_runner | Unduh biner Vina; jalankan dan parse skor |
| docking/docking_matrix | Loop ligan × reseptor × replikat, resume |
| docking/grid_box | Parameter gridbox, ukuran dari native |
| docking/rmsd_validation | RMSD in place (CalcRMS) |
| docking/merge | Kompleks PDB + JSON |
| admet/admetlab_scraper | Scraper ADMETLab 3.0 |
| admet/admet_file | Baca CSV/XLSX ADMET |
| admet/dedup | SMILES unik, salin ke ligan kembar |
| admet/admet_rules | 120 aturan klasifikasi |
| analytics/charts, heatmap | Bar, radar, heatmap (terpecah otomatis) |
| analytics/pca, hca | PCA gaya jurnal dan HCA |
| analytics/paging | Pemecahan plot menjadi bagian |
| analytics/group_stats, group_charts | Statistik dan grafik per grup |
| analytics/style | Gaya grafik bersama |
| similarity/* | Pembaca BIOVIA, rumus, plot, laporan |
| gcms/* | GC-MS: pembaca, sinyal, statistik, pustaka, grafik |
| utils/name_sanitizer, residue_backbone | Nama file aman, deteksi backbone |
| utils/subprocess_stream | Subprocess dan log (logging_setup) |
| templates, system_check, banner | Templat, cek kesiapan, header |

APPENDIX

# Resume: melanjutkan run dari titik terakhir

### Checkpoint atomik

Tiap item yang selesai (ligan, reseptor beserta gridbox, satu run Vina, hasil ADMET) ditulis ke file sementara lalu diganti atomik, jadi aman terhadap mati listrik.

### Folder _state/

Berisi config.json, progress.json, salinan Excel input (inputs/), dan admet_cache.json. Path disimpan relatif, jadi folder hasil boleh dipindah.

### chemflow resume

chemflow resume --output hasil/ membaca konfigurasi dari _state/ lalu melanjutkan. Ringkasan awal menyebut berapa ligan, reseptor, run docking, dan batch ADMET yang dipakai ulang.

### Ctrl+C dan child process

Ctrl+C mengembalikan kode 130 dan mencetak perintah resume. Child process Vina ikut dimatikan, jadi tidak ada proses yatim setelah interupsi.

### Dilewati dan diulang

Run Vina yang sukses dan berkas keluarannya ada dilewati. Run gagal, run terputus, atau checkpoint rusak diulang. Kompleks dianggap selesai bila PDB dan JSON-nya ada.

### Setelan dan batasan

Log level serta jalur OpenBabel atau Vina boleh diganti saat resume; parameter ilmiah tetap dari run awal. Folder tanpa _state (versi lama) ditolak dengan pesan jelas.

**Pemakaian**

chemflow resume --output hasil/ · dari kode: Pipeline(RunState("hasil").load_config(), resume=True).run(). Ekspor Excel dan analitik selalu dibuat ulang karena murah.

APPENDIX

# Native, plot per grup, dan pemecahan plot otomatis

### Native otomatis

Ligan native di-dock ulang dengan parameter dan replikat yang sama, lalu ikut ADMET, Lipinski, heatmap, PCA, dan HCA sebagai grup Native. Matikan dengan --no-native.

### Gridbox dari native

Ukuran kubus = ekstensi native + padding 8 Å (minimal 18, maksimal 30). Berlaku pada mode interaktif dan Excel tanpa ukuran; --default-box-size hanya cadangan.

### ADMET multi-grup

Senyawa yang sama di beberapa grup dikirim sekali (SMILES kanonik), lalu hasilnya disalin ke tiap ligan menurut indeksnya. Berlaku juga untuk --admet-file.

### Plot per grup

Box plot ΔG per reseptor, heatmap grup × reseptor, persentase ligan lebih baik dari native, dan ADMET per grup (heatmap, radar, klasifikasi), plus sheet Ringkasan per Grup.

### Pemecahan plot

Bila baris atau kolom melebihi --plot-max-rows (30) atau --plot-max-cols (20), gambar dibagi _part01of03 dan seterusnya dengan skala warna dan sumbu yang sama.

### RMSD in place

RMSD native dihitung tanpa superposisi ulang (CalcRMS) dari pose terbaik lintas replikat. Ambang: < 2,0 Å baik, 2,0 sampai 3,0 Å cukup, ≥ 3,0 Å buruk.

**Cara membaca**

Grup Native adalah pembanding: garis putus-putus pada plot ΔG dan kolom Native (ref) pada heatmap menunjukkan skor ligan kristal pada reseptor yang sama.

APPENDIX

# Interaksi otomatis dari BIOVIA untuk similaritas

### Sekali jalan

chemflow run menyambung dari docking ke ekspor interaksi lalu similaritas, otomatis bila BIOVIA terdeteksi. chemflow interactions dan chemflow similarity tetap bisa dipakai terpisah.

### Deteksi instalasi

DiscoveryStudio<tahun>.exe dicari di registry App Paths dan Program Files. Tahun terbaru dipilih, folder tanpa bin diabaikan, --biovia-exe menimpa.

### Galat lisensi teratasi

Popen tidak membawa PATH dari registry App Paths yang dibutuhkan modul lisensi BIOVIA. chemflow menambahkannya, jadi BIOVIA terbuka tanpa galat lisensi.

### Kendali lewat pohon UI

Tombol, tab, dan tabel dicari lewat nama dan kelas kontrol, bukan koordinat layar. Fokus jendela diperiksa sebelum tiap input dikirim; input Anda dikunci.

### Keluaran

interaksi/<kunci>/<basis>_interaksi.png dan .xlsx (tabel Non-bond). Kompleks yang sudah lengkap dilewati, jadi ekspor yang terhenti bisa dilanjutkan.

### Batasan

Hanya Windows. Mouse dan keyboard dikunci selama ekspor (sekitar 20 detik per kompleks); Esc tiga kali membatalkan. Diuji pada Discovery Studio 2021.

**Perintah**

```
python -m chemflow run --ligands ligan.xlsx --receptors reseptor.xlsx --output hasil/
```

APPENDIX

# Analisis GC-MS opsional (chemflow 2.0)

### Mandiri dan opsional

chemflow gcms --data ... --output ... berjalan tanpa docking dan bisa diulang pada folder yang sama. chemflow run --gcms menambahkannya sebagai tahap akhir; tanpa argumen GC-MS pipeline tidak berubah.

### Banyak format

Ekspor Shimadzu (xls, xlsx, txt), CSV/TSV, ANDI-MS .cdf, mzML, mzXML: kromatogram, tabel puncak, atau matriks fitur. Satuan RT, termasuk menit terkali 1000, dikoreksi otomatis.

### Pemrosesan sinyal

Baseline ALS, Savitzky-Golay, penyelarasan RT lewat korelasi silang, deteksi puncak berbasis S/N, pengelompokan puncak antar sampel, dan sidik jari per bin waktu.

### Kemometrik dan statistik

PCA gaya jurnal, HCA, kemiripan, uji univariat dengan koreksi FDR, PLS-DA dan LDA dengan validasi silang, uji permutasi, skor VIP, dan pencilan T2.

### Identifikasi dan alergen

Nama dari laporan instrumen, pustaka RT atau RI, dan indeks Kovats. Skrining 24 alergen wewangian UE; senyawa bernama bersmiles jadi daftar ligan untuk docking.

### Batasan

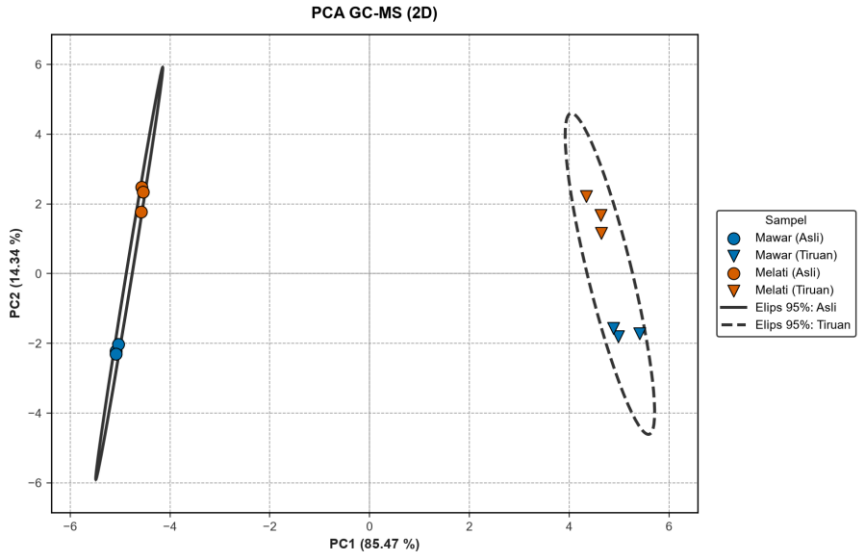
Hanya TIC, tanpa pencocokan spektrum. Persen luas puncak bukan konsentrasi. Model terawasi butuh minimal 6 sampel dan 2 per kelas, dan kurang bermakna dengan sedikit ulangan.

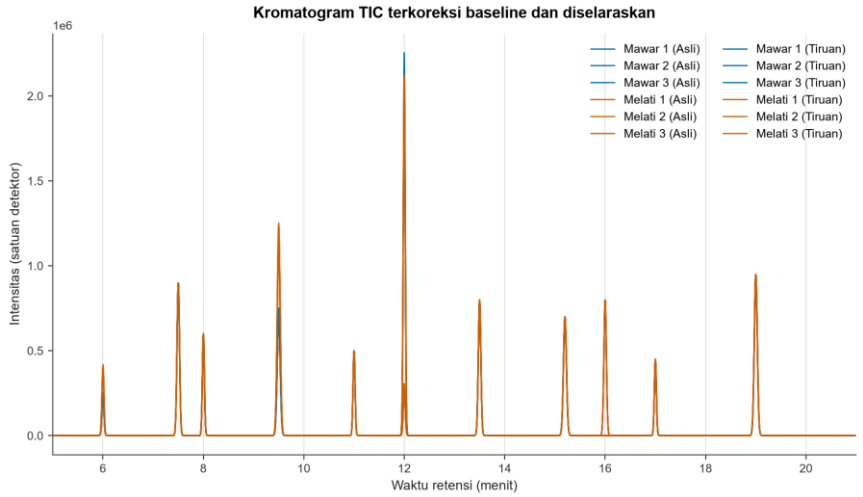
**Perintah**

```
python -m chemflow gcms --data data-gcms/ --output hasil/
```

APPENDIX

# GC-MS: PCA gaya jurnal dan kromatogram (data sintetis)




pca_2d.png dan kromatogram_tumpang_tindih.png dari studi sintetis: 2 kelas x 2 seri x 3 ulangan.

Studi sintetis dibuat oleh tests/gcms_data.py; format masukan asli: xls, csv, cdf, mzML, mzXML.

## Cara baca

- Warna: seri (Mawar, Melati)
- Penanda: kelas (Asli, Tiruan)
- Elips 95% per kelas, gaya garis berbeda
- Puncak 12,0 dan 16,0 menit sengaja dibuat berbeda
- PLS-DA dan LDA: akurasi validasi silang 100%, p permutasi < 0,05

*Data sintetis untuk ilustrasi, bukan hasil pengukuran.*

# Validasi RMSD saja: redocking native tanpa ligan uji

```
chemflow run --rmsd-only --receptors reseptor.xlsx --output validasi/
--no-similarity
```

1. Siapkan reseptor dan ligan native dari struktur kristal.
2. Redock native hanya ke reseptor asalnya.
3. Hitung RMSD setiap pose dari seluruh replikat sukses.
4. Pilih minimum; simpan mode, replikat, seed, dan afinitas.

--ligands diabaikan; ADMET dan analitik screening dilewati.

Gunakan --run-rmsd-validation untuk menambahkan validasi ke pipeline penuh.

# Merge dan interaksi RMSD memilih pose secara terpisah

```
--merge-mode best : afinitas docking utama
--rmsd-merge-mode best/all : minimum RMSD / semua pose
--rmsd-interaction-mode best/all: pilihan interaksi RMSD
```

Contoh: pose 1 = -9 kcal/mol, RMSD 3,5 Å; pose 2 = -7 kcal/mol, RMSD 0,8 Å.
Best docking memilih pose 1. Best RMSD memilih pose 2.

rmsd/hasil_rmsd.xlsx: ringkasan minimum + seluruh pose
rmsd/complexes/: mengikuti opsi merge RMSD
rmsd/interaction_source/complexes/: mengikuti opsi interaksi RMSD
rmsd/interaksi/: diagram 2D dan tabel BIOVIA

Ekspor kemudian: chemflow interactions --output validasi/ --rmsd

# Open Babel: temukan instalasi dan simpan path sekali

Urutan pencarian

Path eksplisit → preferensi tersimpan → PATH → lokasi instalasi umum

```
chemflow run --rmsd-only --receptors reseptor.xlsx --openbabel-path "C:/Program
Files/OpenBabel-3.1.1/obabel.exe" --output validasi/ --no-similarity
```

Run berikutnya cukup tanpa --openbabel-path.

Windows: %LOCALAPPDATA%/chemflow/openbabel.json

Cache rusak atau file hilang: lanjutkan pencarian instalasi.

Folder portable lain: tentukan path manual sekali.